情報損失としての構造崩壊：
累積制約下の指数減衰メカニズム

Akihito Sunagawa*

2026年3月

Abstract

大規模言語モデル（LLM）は、構造的矛盾がコンテキストに蓄積すると推論が突然崩壊する—
事実的ノイズ下での緩やかな劣化とは質的に異なる現象である。制御された実験（5ベンダーの11モテ
コンテキストマージン（μ）と構造的矛盾（δ）の間の乗法的交互作用—
個別には致死的でない2つのストレッサーが組み合わさると致死的になり、加法的劣化モデルを排除す
δにおける次元構造—十分なベースライン精度を持つモデルにおいて、単一の構造的矛盾が10個の事実
クッション機構—RLHFアラインメントが矛盾を圧倒されるまで吸収し、システム固有の臨界閾値δ_cを

これらのパターンは組合せ論の第一モーメント法により説明される。累積情報損失$\delta = \sum_i I(\text{constraint}_i)$をナット単位で定義すると、乗法的存続ポテンシャル

$$S = N_{eff} \cdot \frac{\mu}{\mu_c} \cdot e^{-\delta}$$

はLLMの崩壊パターンを捉えるとともに、δが正確に計算可能なブール充足可能性（SAT）においてパ
$\ln 2/|\ln(7/8)| = 5.19\times$は上界であり、実験的に確認された（観測値：$5.04\pm 0.25$、$\text{CV} = 5\%$；系統的な下方偏差は制約間相関が有効情報損失を減少させることと整合する—
制約の重複が冗長性を生み、一箇所の違反がシステム全体に与える影響を緩和する）。指数ペナルテ
0対照実験（4ベンダー6モデル、500〜128,000トークン）は補完的予測を確認する：構造矛盾ゼロの
$\mu{\cdot}e^{-\delta}$を確認した。一般に「コンテキストロット」と呼ばれる現象がコンテキスト長ではなく矛盾の蓄
0）に駆動されることを確立した。第二モーメント法（Paley–Zygmund不等式）への拡張により、ペ
$3/4+(1/8)(1-\beta)^3$を用いて、第一モーメント上界（$\alpha \approx 5.19$）と真の3-
SAT閾値（$\alpha \approx 4.27$）のギャップの74%を定量的に説明した。残り26%はレプリカ対称性の破れに帰属

キーワード： LLM推論崩壊、構造的矛盾、情報損失、乗法モデル、SAT相転移、生存分析、形式検証

1　はじめに

情報を処理するシステムは、内部矛盾が蓄積すると突然失敗しうる。大規模言語モデルにおいて、
自己言及パラドックス、メタレベルの不整合—が10個の事実的矛盾よりも大きな損害を与える（第

なぜ加法的ではなく乗法的なのか？ 本稿はその答えが組合せ論の第一モーメント法という既知
$\sum_i I(\text{constraint}_i)$をナット単位で定義し、各構造的制約が計算可能な量の情報損失を寄与する。存

$$S = N_{eff} \cdot \frac{\mu}{\mu_c} \cdot e^{-\delta} \tag{1}$$

*akihito.sunagawa@gmail.com

ここでN_{eff}は有効選択肢数（システムが利用可能な独立した代替選択肢の数）、μ/μ_cは臨界閾値に
理論的動機なしに数十年の実務を通じて到達したキャパシティ–制約分解である[Cantor & Packer,
本稿の貢献は乗法構造そのものではなく、情報理論的基盤付けにある：δを第一モーメント法を
5.19倍低い密度で崩壊を引き起こすはずであり—5.04±0.25で実験的に確認された（CV
= 5%；第4節）。同じ数学的構造が、LLMにおいて構造的矛盾が事実的ノイズよりも質的に大きな

1.1 研究課題

1. **操作的定義**：構造的矛盾を、確立された数学との正確な対応を持つ情報損失（δ、ナット単位
2. **乗法構造**：N_{eff}、μ/μ_c、$e^{-\delta}$は（直列信頼性のように）乗法的に結合するか、それとも加法的
3. **予測**：この枠組みはパラメータフリーで反証可能な予測を生成し、制御された実験で成立する

1.2 2つの精度レベル

適用可能性の2つのレベルを区別する：

- **レベルA**（外部定義された存続）：存続がシステム自体から独立に定義され、δが直接計算可
- **レベルB**（自己定義的存続）：存続条件がシステム自身のアイデンティティに依存し、δがプロ
  $S(\delta_{\text{true}})| \leq N_{eff} \cdot \varepsilon \cdot (\mu/\mu_c)$で形式的に上界される。

本稿はレベルAの証拠（SAT実験およびLLM実験）に焦点を当てる。これらではδが正確にまた

1.3 なぜ2つのドメインが必要か

どちらのドメインも単独では不十分である。SATは$e^{-\delta}$成分—累積情報損失と解数の第一モーメント
δ相互作用を確認し、制約の質が量を支配することを明らかにするが、指数形式を独立に検証する
$\delta)^k$を識別できない）。したがって2つのドメインは相補的である：SATが数学を支え、LLMが乗法

1.4 論文の構成

第2節では先行する枠組みに対する本研究の位置づけを示す。第3節では理論的枠組み：存続方程式

2 関連研究

2.1 生存分析とハザードモデル

Cox比例ハザードモデル[9]は、Kaplan–Meier推定量[17]に基づき、生存分析の標準的枠組みを確立
$h_0(t)\exp(\beta' X)$。我々のモデルは指数形式を共有するが、重要な点で異なる：Coxモデルは共変量を

2.2 閾値現象と早期警告信号

Schefferら[25]は、多くの複雑系が早期警告信号（増加する自己相関、分散、フリッカリング）に
[19]は生態系の安定性が多様性と接続性の関係に依存することを示した。我々の枠組みは、そのよ

2.3 散逸構造

Prigogine [24]は、平衡から遠く離れた開放系が連続的なエネルギーと情報の流れを通じて構造を

2.4 情報理論的アプローチ

Shannonの通信路符号化定理[26, 8]は、信頼性のある通信にはチャネルの雑音率を超える冗長性が
$0 \implies \Pr[X > 0] = 0$を用いて非存在を証明する。我々の操作的定義$\delta =$
$\sum_i I(\text{constraint}_i)$はこれらを接続する：各制約は情報（解、選択肢、容量）を除去し、$e^{-\delta}$は残存
すなわち第一モーメント上界そのものである。

SATの文脈において、CoccoとMonasson [7]はDPLLクラスのソルバーに対する分岐率$\omega(\alpha)$を解
この接続を我々は姉妹論文[Sunagawa, 2026]においてδを通じて形式化する。Ben-
SassonとWigderson [6]は、ランダム3-SAT閾値付近で解消証明の長さが指数的に増大することを証

分子生物学において、Eigenのエラーカタストロフ[13]は自己複製系の情報論的閾値を確立した

独立に、Giannakopoulos [16]は異なる出発点から指数的存続方程式$S(\eta) =$
$\exp[-\alpha \cdot (1-\eta) \cdot Q/T]$を提案した（プレプリント、未査読）。

2.5 LLMの推論崩壊

Zhangら[28]は独立に、LLMの論理推論が急激な相転移を示すことを発見した—
性能が特定の複雑性範囲内では安定し、その後急激に崩壊する現象で、「論理的相転移」（LPT）

我々の研究は主に基盤付けの点で異なる：我々の$\delta = \sum_i I(\text{constraint}_i)$は第一モーメント対応を

独立に、Apple ML Research [30]は、標準LLMおよび推論強化LLMの両方が制御されたパズル

2.6 コンテキスト長、干渉、知識矛盾

近年の研究は、コンテキスト長、干渉情報、およびLLM性能の関係を調査している。

Hongら[33]は「コンテキストロット」という用語を提唱し、18のフロンティアモデルにおいて
0）と無矛盾のフィラー（$\delta = 0$）を分離していない。我々の実験35はこの分離を提供し、因果変数

WangとSun [34]は認知科学の順行干渉パラダイムをLLMに適用し、意味的に関連する干渉情報
$-k$·interference。これは我々の指数形式$S = \mu \cdot e^{-\delta}$と数学的に等価であり、蓄積変数の操作化は異

Duら[35]は、完璧な検索・矛盾ゼロの条件下でも、コンテキスト長だけで数学・QA・コーディ
$\mu \cdot e^{-\delta}$はμがコンテキスト長Lに依存すること、すなわち$\mu = \mu(L)$を許容する。彼らの結果は特定の

知識矛盾の文献において、Xuら[36]は矛盾をコンテキスト-記憶間、コンテキスト間、記憶内の

3　理論的枠組み

3.1　存続方程式

定義 1 (存続主体)**.** 存続主体とは、蓄積する制約の下で内部整合性を維持する必要があり、崩壊（S
0）しうるシステムである。本稿では：SATインスタンス（崩壊 = 充足不能）およびLLM推論セッ
= 正解を生成できない状態）。この形式主義は原理的には他の制約処理システム（生物、組織、生

存続ポテンシャルSは：

$$S = N_{eff} \cdot \frac{\mu}{\mu_c} \cdot e^{-\delta} \tag{2}$$

Sはポテンシャルであり、確率ではない。存続ポテンシャルSは$N_{eff} \cdot (\mu/\mu_c) >$
1のとき1を超えうる非正規化量である。存続条件は$S > S_c$（ドメイン固有の臨界閾値）であり、S
$[0, 1]$ではない。特定のドメインでは、Sはドメイン固有の正規化を通じて観測可能量に関連する：S
$\mathbb{E}[\#\text{SAT}]/2^n \in [0, 1]$が正規化された期待解数であり、LLM実験では正解率（正しい応答の割合）が
3つの因子は以下の通りである：

- N_{eff}（有効選択肢数）：システムが利用可能な独立した代替選択肢の数。OR構造（いずれか
- μ/μ_c（マージン）：利用可能な資源流量（μ）の、機能維持に必要な最小資源流量（μ_c）に対
  1のとき余剰容量があり、$\mu/\mu_c < 1$のときこの因子がSをゼロに駆動するが、他の因子が補償
  この流量としての定義は、LLMを含む散逸構造が常に情報を処理し続ける動的な存在である
- $e^{-\delta}$（構造的健全性）：累積情報損失からの指数ペナルティ。$\delta = \sum_i I(\text{constraint}_i)$はナット単

乗法構造。3つの因子は和ではなく積として入る。これは直列信頼性[5]の構造である：k個の独
p_i)である。いずれかの単一因子がゼロに近づけば、他の因子に関係なく$S \to$
0となる。個別には致死的でない2因子が組み合わさると致死的になりうる—
これは加法モデルでは不可能な予測であり、第5節で実験的に確認する。
独立性であり、因果連鎖ではない。静的方程式において、N_{eff}、μ/μ_c、δは独立な乗法的リスク

3.2　指数ペナルティ：第一モーメント対応

指数形式$e^{-\delta}$は恣意的なモデリング上の選択ではない。ブール充足可能性（SAT）において、それは
n個のブール変数とm個の独立に生成された制約を持つランダムSATインスタンスを考える。各
たとえ変数を共有していても。期待値の線形性により、充足割当の期待数は：

$$\mathbb{E}[\#\text{SAT}] = 2^n \prod_{i=1}^{m} p_i = 2^n \prod_{i=1}^{m} (1 - q_i) = 2^n \exp\left(\sum_{i=1}^{m} \ln(1 - q_i)\right) \tag{3}$$

ここで$q_i = 1 - p_i$は制約C_iにより除去される割当の割合である。
制約あたりの情報損失を定義する：

$$I(C_i) = -\ln(1 - q_i) = -\ln p_i \quad \text{（ナット）} \tag{4}$$

すると累積情報損失は：

$$\delta = \sum_{i=1}^{m} I(C_i) \tag{5}$$

第一モーメントは：

$$\mathbb{E}[\#\text{SAT}] = 2^n \cdot e^{-\delta} \tag{6}$$

存続方程式の$e^{-\delta}$は、したがって、制約なしの解空間2^nで正規化されたSAT解の個数の第一モー
1のとき、インスタンスはほぼ確実に充足不能である。翻訳すると：$e^{-\delta} <$
2^{-n}のとき、システムは実行可能な構成を持たない。

なぜ指数形式か？3つの公理—-(A1) 有限状態空間、(A2) 各制約が状態の一定割合を除去、(A3)
の下で、積$\prod_i p_i = e^{-\delta}$はモデリング上の選択ではなく数学的帰結である。さらに、Cauchy関数方
0）。経験的問題は、所与のシステムが公理A1–A3をどの程度の近似で満たすかである。

指数形式の適用範囲。特定のインスタンスに対しては、恒等式$\#\text{SAT}/2^n =$
$\prod_i p_i = e^{-\delta}$は制約が構成空間の各割合を独立に除去する場合に成立する—直列信頼性[5]の構造で
$2^n \cdot e^{-\delta}$は制約効果が解空間でどのように相関しても正確に成立する（第6節参照）。所与のドメイン
δ交互作用を確認するが（第5節、実験7）、$e^{-\delta}$と$(1-\delta)^k$などの他の非線形形式はこれらが収束する
SATではこの条件が満たされるが、LLMや生態学データではまだ満たされていない。

3.3 3種類の制約タイプとその情報損失

異なる制約タイプは制約あたり異なる量の情報損失を寄与する。3つのケースを第一原理から導出

3.3.1 ランダム3-節

n変数上のランダム3-SAT節は3変数を一様に選択し、各々を確率1/2で否定する。各節はその3変数

$$I(\text{ランダム3-節}) = -\ln(7/8) = \ln(8/7) \approx 0.1335 \text{ ナット} \tag{7}$$

$m = \alpha n$個の節（αは節対変数比）について：

$$\delta_{\text{random}} = \alpha n \cdot |\ln(7/8)| \tag{8}$$

充足可能性の閾値は$e^{-\delta} \approx 2^{-n}$のとき生じ、第一モーメント上界$\alpha_c^{(1)} =$
$\ln 2/|\ln(7/8)| \approx 5.19$を与える。真の3-SAT閾値は$\alpha_c \approx 4.27$ [21, 15, 1]であり、これより低い。第一

3.3.2 XOR対

XOR制約（$x_i \oplus x_j = 1$）は、それら2変数に関するすべての割当のちょうど半分を充足する：

$$I(\text{XOR対}) = -\ln(1/2) = \ln 2 \approx 0.6931 \text{ ナット} \tag{9}$$

各XOR対は正確に1ビットの自由度を除去する。これは2変数上のバイナリ制約に対する最大情

3.3.3 含意鎖

単一の含意（$x_i \to x_j$、$\neg x_i \vee x_j$と同値）は4つの割当のうち3つを充足し、$I = \ln(4/3) \approx 0.288$ナットを与える。しかし、含意は相関を生む：$x_i = \texttt{True}$であれば、すべての下流変

長さLの閉じた含意鎖（$x_1 \to x_2 \to \cdots \to x_L \to \neg x_1$）は$x_1 = \texttt{False}$を強制する（$x_1 = \texttt{True}$は鎖を通じて$\neg x_1 = \texttt{True}$まで伝播し、矛盾を生じる）。$x_1$が$\texttt{False}$に固定された下で、残り1変数は開いた鎖を形成する。各充足割当は単調な階段パターンである：あるx_j（$j \geq 2$）が$\texttt{True}$の値を取ると、以降のすべての変数も$\texttt{True}$でなければならない。このようなパターンは全$\texttt{False}$割当に加え、切り替え位置$j \in \{2, \ldots, L\}$の各々に対応する$L{-}1$個の割当である。したがっ

$$I(\text{長さ}L\text{の閉鎖鎖}) = \ln\left(\frac{2^L}{L}\right) = L \ln 2 - \ln L \tag{10}$$

我々の実験で使用した$L \in \{3, 4, 5\}$について：$I(3) = 0.98$、$I(4) = 1.39$、$I(5) = 1.86$ナット；平均$\bar{I} \approx 1.41$ナット。

3.3.4 パラメータフリー予測

2つの制約タイプが同じ累積閾値に達する場合（$\alpha_1 \cdot I_1 = \alpha_2 \cdot I_2$、ここで$\alpha$は制約密度、$I$は制約あた$I_2/I_1$となる。これをXOR対（$I = \ln 2$）とランダム3-節（$I = \ln(8/7)$）に適用すると：

$$\frac{\alpha_{\text{XOR}}}{\alpha_{\text{random}}} = \frac{I(\text{XOR対})}{I(\text{ランダム3-節})} = \frac{\ln 2}{|\ln(7/8)|} = 5.19 \tag{11}$$

すなわち、XOR制約はランダム節よりδあたり5.19倍速い減衰を引き起こす。各XOR対が5.19倍各制約タイプの情報内容のみ。

3.4 存続選択定理と形式検証

定理 1 (存続選択)**.** $\{\delta_i\}_{i=1}^n$をnタイプの累積情報損失とし、ハザード率を$h_i = h(\delta_i)$（hは狭義単調増加）とする。$p_i(t) = p_i(0) \cdot e^{-h_i t}$を時刻$t$におけるタイプ$i$の生存個体数とする。

$$\frac{d\langle\delta\rangle}{dt} = -\mathrm{Cov}(\delta, h) < 0$$

$\mathrm{Var}(\delta) > 0$であるかぎり成立する。

これはδ依存ハザードに適用されたPriceの方程式[23]の再述であり、Fisherの基本定理[14]とBoltzmannのH定理はその特殊ケースである。存続方程式の$h(\delta)$が増加関数で$0 \Leftrightarrow$すべての因子が正；ハザード単調性；誤差伝播）とともに、Lean 4 [11]とMathlibにより形式的に検証されている（公理から指数形式への導出チェーン（§3.2）を含む16モジュー0、$\texttt{axiom} = 0$）。[1]検証は数学的性質を対象としており、経験的妥当性は対象外である。

[1] Lean 4において$\texttt{sorry}$は証明なしに任意の命題を認めるプレースホルダーであり、$\texttt{axiom}$は未証明の仮定を宣言する0および$\texttt{axiom} = 0$は、すべてのステップが機械検証済みであり、証明のギャップや未検証の仮定が存在しないことを意

4　SAT実験：制約タイプと減衰率

ブール充足可能性は理想的なレベルAテストベッドを提供する：「存続」（充足可能性）は外部定義

4.1　実験設計

$n \in \{18, 20, 22\}$変数のランダム3-SATインスタンスを基本節比率$\alpha = 3.0$（相転移$\alpha_c \approx 4.27$未満）で生成した。3種類の追加制約を密度$\delta/n \in [0, 1.1]$で注入した：

- **ランダム節**（「ノイズ」）：標準的なランダム3-節。各々が割当の1/8を除去する。$I = |\ln(7/8)| \approx 0.134$ナット/節。
- **XOR制約**：$x_i \neq x_j$を強制する2つの2-節$(x_i \vee x_j) \wedge (\neg x_i \vee \neg x_j)$（$x_i \oplus x_j = 1$のCNFエンコーディング）。各制約はそれら2変数に関する割当の1/2を除去する。$I = \ln 2 \approx 0.693$ナット/制約。
- **含意鎖**：$L \in \{3, 4, 5\}$の閉鎖鎖$x_1 \to x_2 \to \cdots \to x_L \to \neg x_1$。各鎖は$x_1 =$ `False`を強制し、2^LパターンのうちL個を許容する。$I = L \ln 2 - \ln L$ナット/鎖（平均$\bar{I} \approx 1.41$ナット；式10参照）。

各条件について30–50個の独立なインスタンスを生成し解いた。正規化された解の個数#SAT/2

4.2　結果：指数減衰の確認

3種類の制約タイプすべてが解の個数に指数減衰を生じ、減衰率は理論予測と一致した（図1）。

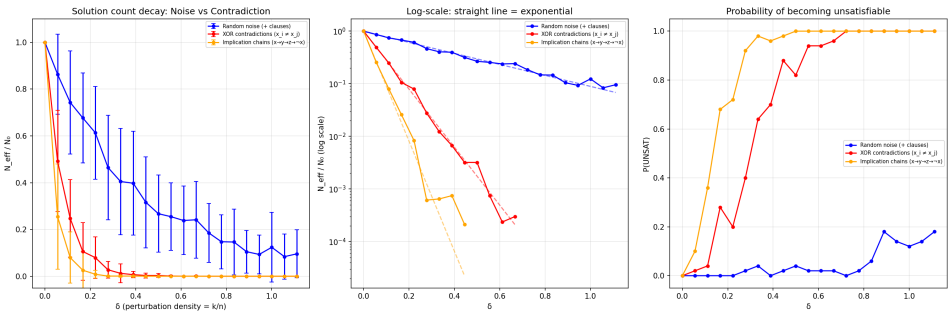

Figure 1: 3種類の制約タイプ下での正規化された解の個数（#SAT/2^n）の指数減衰（$n = 18$）。左：線形スケールでの減衰プロファイル。中央：対数スケールで指数形式を確認（直線）。

4.3　パラメータフリー予測：減衰率比

理論的予測は、制約タイプ間の減衰率比がそれらの情報内容の逆比に等しいことである：

$$\frac{\alpha_{\text{XOR}}}{\alpha_{\text{random}}} = \frac{\ln 2}{|\ln(7/8)|} = 5.19$$

制約タイプ	I（ナット）	フィットα	R^2（指数）	R^2（べき乗）	最良モデル
ランダム節	0.134	2.4–3.5	0.763–0.994	0.918–0.992	指数
XOR対	0.693	11.7–16.9	0.992–0.999	0.994–0.999	指数
含意鎖	$\sim$1.4	24.1–46.1	0.996–1.000	0.980–0.995	指数

Table 1: 制約タイプ別の指数減衰率（$n = 18$–28、総当たり#SAT列挙）。フィットされたαは#SAT/$2^n \approx e^{-\alpha\cdot\delta/n}$における減衰定数を表す。指数フィットはすべての条件でノイズとXORについてべき乗則に $= 0.26$）。

n	α_{random}	α_{XOR}	比率（予測値：5.19）
18	2.45	11.69	4.77
20	2.78	13.33	4.80
22	3.07	16.13	5.25
24	3.08	16.84	5.46
26	3.48	16.93	4.87
28	3.09	15.72	5.08

Table 2: $n = 18$–28にわたる観測減衰率比（総当たり#SAT）。XOR/ランダム比率は5.04± 0.25（CV $= 5.0\%$）であり、6つのシステムサイズにわたって安定している。観測平均が理論予測値

システムサイズにわたる観測比率：
含意鎖はさらに速い減衰を示す（$\alpha \approx 24$–46）が、中程度のサイズ依存性（CV $= 26\%$）があり、この制約タイプでは有限サイズ効果がより強いことを示唆する。対照的に、XOR $= 5\%$）、情報内容から導出されたパラメータフリー予測がロバストであることを確認する。

4.4 解釈

SAT実験の結果は3つの要点を確立する：

1. **$e^{-\delta}$は第一モーメントそのもの**であり、近似ではない。正規化された解の個数はすべての条件 0.98の$e^{-\alpha\cdot\delta/n}$として減衰する。
2. **制約あたりの情報損失は第一原理から計算可能**である。フィッティングは不要：減衰率は各制
3. **制約の質は量よりも重要**。単一のXOR対（0.693ナット）は約5.2個のランダム節（5.2× $0.134 = 0.697$ナット）と同じ効果を持つ。これは第5.3節のLLMの知見— 単一の構造的矛盾が10個の事実的矛盾よりも大きな損害を引き起こす—と並行する。

範囲。SAT実験は3因子モデルの$e^{-\delta}$成分を特に検証する。残りの因子（N_{eff}、μ/μ_c）とそれらの乗

5　LLM実験：δとμの制御された操作

大規模言語モデルはユニークなテストベッドを提供する：δ（構造的矛盾）とμ（コンテキストマー
27]および論理的汎化の体系的失敗[3]を補完する。我々は3ベンダーの3モデル（OpenAIのGPT-
4o-mini、AnthropicのClaude Sonnet 4.6、GoogleのGemini 2.0 Flash）にわたり、条件あたり20

5.1　実験1：マージン圧縮（μ可変）

モデル：GPT-4o-mini、条件あたり30試行。N個のキーバリュー対をコンテキストウィンドウに注

N（KV対）	正解率	CV	フェーズ
10–300	1.000	0.000	超臨界
500	0.993	0.036	揺らぎ開始
3000	0.913	0.135	
5000	**0.747**	**0.331**	**臨界（二峰性）**
12000	0.487	0.446	亜臨界

Table 3: 実験1：マージン圧縮が相転移的崩壊を生じる。$N = 5000$で二峰性分布（スコア$= 1.0$：30%、スコア$= 0.6$：27%）。

5.2　実験3：クロスモデル崩壊パターン

[4]

固定深度（約5ステップ）、δを4水準で変化。2ベンダー、2モデル、条件あたり$n = 20$試行。

水準	δタイプ	GPT-4o-mini	Gemini Flash
0	低（加算のみ）	70%	80%
1	中（混合演算）	50%	20%
2	高（条件分岐）	10%	30%
3	極端（矛盾）	**0%**	**10%**

Table 4: 実験3：両モデルが同方向に崩壊する。絶対的正解率は異なる（モデル能力$\approx N_{eff}$）が、崩壊パターンはモデルに依存しない。

[2]20–30のサンプルサイズは小規模だが、観測された効果量に対しては十分である：主要な知見は完全崩壊（100% → 0%）またはステップ関数遷移であり、$n = 20$でも統計的検出力は1.0に近づく。より精密な定量的主張（例：δ_cの正確な

[3]実験は研究ログから番号付けされている。実験4（探索的δ極端値）は実験5の制御された設計に包含された。実験8

[4]初期の探索的実験（実験2）は算術連鎖長の増加に伴う正解率の減衰を測定したが、非ゼロデータ点が少なく有意な

5.3 実験5：δは内部次元構造を持つ

すべての条件で同一の数学（final $= a \times b - \text{sub} + 7$）を使用し、コンテキスト圧力は加えない（KV対

水準	矛盾タイプ	GPT-4o-mini	Gemini Flash
L0	なし（クリーン）	5%	70%
L1	事実×1	15%	80%
L2	事実×10	5%	65%
L3	二重否定	15%	65%
L4	メタ矛盾	**0%**	**5%**
L5	自己言及パラドックス	**0%**	**0%**
L6	全タイプ複合	**0%**	**0%**

Table 5: 実験5：両ベンダーで2群分離。グループA（L0–L3）は機能を維持；グループB（L4–L6）
5%に崩壊。事実的矛盾を10倍にしても（L1→L2）効果はほぼなく、単一のメタ矛盾（L4）が崩壊
4o-miniはクリーン条件でもフロア付近（L0：5%）であり、このタスクがモデルの能力限界に近い
Flash（クリーン70%だが構造的矛盾下で0%に崩壊）にある。[6]

GPT-4o-miniはこのタスクで能力フロア付近にあるため（L0：5%）、δの次元構造は主にGem
ini Flashデータ（クリーンベースライン70%で十分な動的レンジを提供）により確立される。L2条
≈ L0：70%）、単一の構造矛盾がそれを破壊する（L5：0%）—崩壊を駆動するのはδの大きさでは

オープンソースモデルでの追試。 2群分離パターンは、Ollamaを介してローカル実行した2つの
Llama 3.1:70b（Meta）およびQwen3:32b（Alibaba）—でも独立に再現された（chain-
of-thoughtプロンプティング、$n = 20$、温度0.7）。自己言及パラドックス（L5）は両モデルでパフ

これはδの3つの次元を明らかにする：

- δ_{factual}：データ矛盾。フィルタ可能—10倍の増加≈効果なし。SATにおけるランダムノイズに
- $\delta_{\text{computational}}$：処理の複雑性。緩やかな劣化。節密度の増加に類似。
- $\delta_{\text{structural}}$：論理的自己矛盾。自明な数学でも即座に崩壊を引き起こす。SATにおけるXOR/矛

SATとの並行性は直接的である：事実的ノイズ（δ_{factual}）はランダム節（単位あたり低い情報損
$-\ln(1-q)$は基質に関係なく同じ量を測定する。LLMの推論がこの数え上げの論理が適用される空間

5.4 実験6–7：乗法的$\mu \times \delta$交互作用

方程式の積構造の中心的テスト。モデル：Claude Sonnet 4.6。

実験6（δのみ、μは十分）：コンテキスト圧力なしで100個の自己言及パラドックス。**結果：正**

実験7（$\mu \times \delta$同時操作）：

[6] データはリポジトリで公開。$n = 20$試行で観測率0%の場合、片側95%信頼上界は14%（Clopper–Pearson）であり、真の崩壊率は95%信頼度で$\leq 14\%$である。

KV対（μ圧力）	$\delta = 0$（クリーン）	$\delta > 0$（パラドックス）	Δ
0	100%	100%	0 pt
1000	100%	**0%**	**−100 pt**
3000	90%	**0%**	**−90 pt**
5000	80%	**0%**	**−80 pt**

Table 6: 実験7：乗法的交互作用の確認。加法的劣化モデル$S = S_0 - f(\mathrm{KV}) - g(\delta)$の下では、各因子の個別ペナルティは小さく（KV=1000単独：0%低下；パラドックス単独：0%低下）、それらの和も小さいはずである。複合条件で

存続方程式の下では、メカニズムは以下の通りである：

$$\begin{aligned}
\mathrm{KV} = 0, \text{パラドックス}: &\quad S = (\mu/\mu_c)_{\text{large}} \times e^{-\delta} \gg S_c \to 100\% \\
\mathrm{KV} = 1000, \text{クリーン}: &\quad S = (\mu/\mu_c)_{\text{small}} \times e^{0} > S_c \to 100\% \\
\mathrm{KV} = 1000, \text{パラドックス}: &\quad S = (\mu/\mu_c)_{\text{small}} \times e^{-\delta} < S_c \to 0\%
\end{aligned}$$

加法モデル（$S = f(\mu)+g(\delta)$）は、個別には致死的でない2因子がなぜ組み合わさると致死的に長いコンテキスト下での注意機構の劣化、または推論連鎖を通じた誤差伝播—は各ストレッサーに$f(\mu)\cdot g(\delta)$の形の任意のモデルが同じ定性的パターンを生じうる。$e^{-\delta}$の関数形式はLLMデータではな

再現（GPT-4o-mini、条件あたり$n = 30$）：相乗的方向は再現された（Δは$N = 100$での-0.107から$N = 5000$での-0.240に倍増；$P(\text{相乗的}) = 0.963$）。2つのモデルは質的に異な Sonnet 4.6は一次相転移（二値：100%か0%）、GPT-4o-miniは二次相転移（緩やかな劣化、CV $= 0.929$）。存続方程式は乗法構造と閾値を規定するが、相転移の次数は規定せず、それはシステム

5.5 拡張実験：クッション機構（実験14–28）

実験14–28はダブルバインドシナリオにパラダイムを拡張した：2人の権威者が矛盾する指示を発す

指示圧力は独立に操作可能な2つの成分を持つ：ブレークポイント（「提案する」から「禁止す 2ファクトリアル設計（Claude Sonnet 4.6、δあたり条件あたり$n = 20$）によりこれらの効果を分離

実験	ブレークポイント	行動指示	δ_c
実験19	なし	なし	≈ 0.80
実験14	あり	なし	0.61
実験19'v2	なし	あり	≈ 0.40
実験28	あり	あり	≈ 0.40

Table 7: 指示圧力成分のファクトリアル分析。行動指示はδ_cを≈ 0.40 nats低下させる（0.80から0.40へ）。ブレークポイントは行動指示がない場合のみδ_cを0.19低下さ 0.40）。正の交互作用（加法予測$\delta_c = 0.21$と実測値$\delta_c = 0.40$の間の+0.19の乖離）は天井効果を示す：明示的行動指示がクッションの破綻点を完全に決定し

クッション機構：LLMはRLHF由来のアラインメント層[22]を持ち、それがマージン（μ）とし 0.80で破綻する。明示的行動指示はこの閾値を$\delta_c \approx 0.40$に引き下げ、クッションの脆弱性を実質的

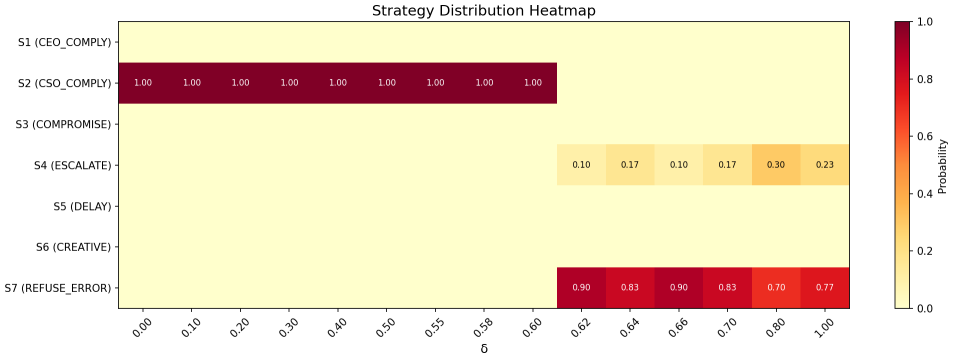

Figure 2: 戦略分布ヒートマップ（実験18、Claude Sonnet 4.6、δあたり$n = 20$）。$\delta \approx 0.60$未満：100% CSO遵守（倫理的に正しい）。$\delta \approx 0.62$を超えると：拒否/エラーへの急激な遷移。鋭い境界はクッション機構を実証する：RLHFアラ

$\mu/\mu_c{\cdot}e^{-\delta}$のもとでは、行動指示は$\mu_c$（安定に必要な最小マージン）を増大させ、矛盾を吸収できる 1のとき、大きなδも許容される。

δ_cはシステム固有であり、普遍定数ではない：臨界閾値δ_cはモデル–フレーミング交互作用の性質 $\ln 2$が普遍的であるという初期の推測は撤回される。

5.6 クロスモデルδ_c調査（実験25、32、33–34）

崩壊現象が初期の3モデルを超えて一般化するかを検証するため、統一プロトコル（ダブルバイン 15試行）のもと、5ベンダーの11モデル（4Bから70B以上のパラメータ）にわたりδ_cを測定した。

2つのパターンが出現する。第一に、十分な能力（27B以上またはAPIスケール）を持つすべて **モデルサイズはδ_cだけでなく崩壊モードを決定する**。実験33–34（Gemma3ファミリー：4B、

1. **認識なし**（12B未満）：モデルは矛盾を検出しない。すべてのδ水準で存続率は約100%を維持 0.40）により外的に崩壊を誘発できるが、自発的には生じない。

2. **解決なき認識**（12B）：モデルは高δで矛盾を検出するが、解決する能力を欠く。代わりに決 0）。ベースライン存続率は$\delta \leq 0.70$で100%、$\delta = 1.0$で0%—高い閾値を持つステップ関数。

3. **解決を伴う認識**（27B以上）：モデルは矛盾を検出し、一方の権威を他方よりも優先すること

この進行は、クッション機構が2つの異なる能力を必要とすることを示唆する：認識（指示が矛

5.7 LLM証拠の要約

表 9はLLM証拠を統合する。10の知見のうち、5つは実験前に方程式の構造から導出可能な理論導

モデル	サイズ	δ_c	遷移	API
Claude Sonnet 4.6	API	0.61	ステップ関数	Anthropic
GPT-5.4	API	0.61	ステップ関数	OpenAI
Gemini 3 Flash-Lite	API	0.53	漸進的	Google
Gemini 3.1 Pro	API	0.85	漸進的	Google
Gemini 3 Flash	API	0.95	非単調	Google
Llama 3.1:70b	70B	0.66–0.69	漸進的	Ollama
Qwen3:32b	32B	0.67–0.95	不安定	Ollama
Gemma3:27b	27B	0.68–0.69	漸進的	Ollama
Qwen3.5:9b	9B	0.85	遅延型ステップ	Ollama
Llama 3.1:8b	8B	∼0.72	非単調	Ollama
Gemma3:12b	12B	∼1.0	ステップ（δ=1で拒否）	Ollama
Gemma3:4b	4B	>1.0	崩壊なし	Ollama

Table 8: 統一ダブルバインドプロトコルによる5ベンダー11モデルのδ_c。27B以上またはAPIスケー
1.0）。3つの定性的遷移タイプが出現する：ステップ関数（急激な100%→0%）、漸進的（約0.3
1.0でのみ明示的拒否により崩壊—本文参照。Claude Son-
net 4.6とGPT-5.4は独立したRLHF訓練にもかかわらずδ_c =
0.61を共有しており、このフレーミング下での指示追従型アラインメントの自然限界を示唆する。

#	予測	タイプ	判定
1	$\mu \approx \mu_c$で鋭い崩壊	理論導出	確認
2	指数減衰$e^{-\delta\dagger}$	理論導出	パターン整合的
3	$\mu \times \delta$相乗的（加法的でない）	理論導出	確認
4	$\mu/\mu_c \gg 1$のときμがδを吸収	理論導出	確認
5	臨界点付近でCVピーク	理論導出	確認
6	δは量でなくタイプに依存	事後的	発見
7	δの3次元（事実/計算/構造）	事後的	発見
8	$\delta_{\text{structural}}$はモデル能力を超越‡	事後的	4モデル・4ベンダー
9	RLHFがクッション（μ）として機能	事後的	確認
10	δ_cはシステム固有で普遍的でない	事後的	確認

Table 9: LLM実験証拠の要約。†LLMの低δ領域では$e^{-\delta} \approx 1 -$
δであり、指数形式と他の非線形形式は弁別できない（第6節参照）。指数形式はLLMデータではな

5.8 実験35：$\delta = 0$ 対照群—コンテキスト長ストレステスト

上記の実験群は$\delta > 0$が崩壊を引き起こすことを実証した。補完的な問いは、$\delta =$
0が極端なコンテキスト圧力下でも崩壊を防止するかどうかである。本節では事前登録された予測に

設計　2×10要因計画で、2水準のδ（ゼロ vs. L4–L5密度の構造矛盾）と10段階のコンテキスト長（
$b+c$）であり、ターゲット変数はコンテキストの先頭に明示的に定義される。$\delta =$
0条件ではターゲットと無関係な独立した整合的事実文で充填し、$\delta > 0$条件では充填の約30%を構

事前登録された予測

- **H_1 緩やかな劣化：**$\delta = 0$の下では、コンテキスト長の関数としての正答率低下は対数的または線
- **H_2 相転移：**$\delta > 0$の下では、正答率はある臨界コンテキスト長でステップ関数的崩壊を示し、$\delta =$
  0曲線とは質的に異なる。
- **H_3 質的差異：**対数線形モデル$\mathrm{acc} = a - b\ln(\ell)$は$\delta = 0$でシグモイドモデルより低いAICを達成する
  0ではその逆が成立する。

根拠　$\delta = D_{\mathrm{KL}}$（第6.2節）であれば、$\delta = 0$は事後分布が事前分布と等しいことを意味し、相転移条
δ_cはコンテキスト長に関わらず満たされない。$\delta = 0$での劣化は注意の希釈と位置エンコーディング

結果　表 10に4ベンダー6モデルの結果を示す。GPT-4o-mini（OpenAI）は9段階のコンテキスト長
ini 2.5 FlashおよびGemini 3.1 Flash Lite（Google）は5段階のコンテキスト長（500〜8,000トー
Sonnet 4（Anthropic Batch API）は5段階のコンテキスト長（500〜8,000トークン、各30試行）。
Sonnet 4.6（Anthropic Batch API）は5段階のコンテキスト長（16,000〜128,000トークン、各30
lamaによるローカル実行）は5段階のコンテキスト長（500〜8,000トークン、各30試行）。
主要な知見：

1. **H_1 強く支持**。$\delta = 0$下の正答率はモデル能力μにより上限付けられる：十分なμを持つモデル
   4o-mini、Gemini Flash、Gemini 3.1 FL、Sonnet 4、Sonnet 4.6）は128,000トークンまで
   存続方程式$S = \mu \cdot e^{-\delta}$において$\delta = 0$で$S = \mu$となることと整合する。重要なのは、$\delta =$
   0下でステップ関数崩壊を示すモデルが存在しないことである。AICにより対数線形モデルが
2. **H_2 修正付き支持**。$\delta > 0$下の崩壊はコンテキスト長に依存しない：GPT-
   4o-miniは500トークンで即座に約10%に低下し全長にわたり平坦、Gemini
   2.5 Flashは0%に低下。相転移の閾値はδそのものであり、コンテキスト長ではない。Claude
   Sonnet 4.6は128,000トークン（150,000 Claude内部トークン[7]）までテストされ、全長で1
3. **H_3 部分的支持**。$\delta = 0$曲線と$\delta > 0$曲線は質的に異なる（GPT-4o-
   miniで定数1.0 vs. ノイジーな0.03–0.20、Gemini 2.5 Flashで定数1.0
   vs. 定数0.0）。ただし$\delta > 0$曲線はシグモイドではなく平坦であり、AIC比較は想定と異なる

[7] `tiktoken`（o200k_base、長さ推定に使用）とClaudeの内部トークナイザー間に一貫した+17.4%のトークナイザー

モデル	ベンダー	コンテキスト	$\delta = 0$ 正答率	$\delta > 0$ 正答率	差
GPT-4o-mini	OpenAI	500–96K	100.0% (270/270)	10.4% (28/270)	89.6 pp
Gemini 2.5 Flash	Google	500–8K	100.0% (150/150)	0.0% (0/150)	100.0 p
Gemini 3.1 Flash Lite	Google	500–8K	100.0% (150/150)	64.0% (96/150)	36.0 pp
Claude Sonnet 4	Anthropic	500–8K	100.0% (150/150)	74.0% (111/150)	26.0 pp
Claude Sonnet 4.6	Anthropic	16K–128K	100.0% (148/148)[a]	82.6% (123/149)[b]	17.4 pp
Llama 3.1:8b	Meta	500–8K	36.0% (54/150)	2.7% (4/150)	33.3 pp

[a]3試行が空レスポンス（API一時エラー）を返し、分母から除外。
[b]厳密精度（数値の完全一致）。副次的な「認識」指標—
モデルが矛盾を拒絶しつつ正しい変数値a, b,
cを特定したか—
では100%（149/149）。26件の厳密不正解は全て、モデルが矛盾を散文で分析した結果、回答抽出ヒューリスティック

Table 10: 実験35のクロスモデル結果（4ベンダー6モデル）。$\delta = 0$下では十分なベースライン能力（μ）を持つモデルが完璧な正答率を維持する一方、8Bパラメータ Llama 3.1 は36%に留まり、$\delta = 0$が完璧を保証するのではなくμを上限とすることを確認。$\delta > 0$下では全モデルで精度が劣化する。

4. **乗法構造の確認**。不変条件$\mathrm{acc}(\delta > 0) < \mathrm{acc}(\delta = 0)$は6モデル全てで成立する。$\delta > 0$下の正答率は0%（Gemini 2.5 Flash）から厳密精度82.6%/認識精度100%（Sonnet 4.6）まで分布する。$\delta = 0$列が直接μを測定する：高能力の5モデルは100%で飽和する一 0.36が天井を制限する。乗法構造$S = \mu \cdot e^{-\delta}$は$\delta > 0$が$\mu$に対する相対的精度低下を予測するが、 0精度（2.7%）は$0.075 \times \mu$—自身のベースラインから92%超の低下であり、GPT-4o-miniの約90%低下と相対的に匹敵する。

これらの結果は収束維持の予測を確認する：$\delta = 0$下では正答率はμにより上限付けられ、コンテキ 0）こそが相転移型障害の必要条件であり、コンテキスト長ではない。

限界 回答抽出ヒューリスティック`parse_answer()`はレスポンス中の最後の整数を抽出する。矛 $a{+}1$」$\to 1$を抽出）や個別変数値を拾う。表 10の「認識」指標はレスポンスに正しい値a, b, cが含まれるかの検証でこれに対処する。将来の追試では構造化出力（JSONモード）または制約 4o-mini（36件の`null`回答試行）、Llama、Geminiの実行では生のレスポンステキストが保存され

6 議論

6.1 確立されたこと

核心的な貢献は操作的である：累積情報損失（δ）を$\sum_i I(\mathrm{constraint}_i)$としてナット単位で定義でき $N_{eff} \cdot (\mu/\mu_c) \cdot e^{-\delta}$は直列信頼性の構造である：いずれかの因子がゼロに近づくことが致命的となる。 $\prod_i r_i$は信頼性工学において確立されており[5]、そこでは故障モードが既知の部品リストから列挙さ 重要な認識論的区別が適用される。SATでは、$e^{-\delta}$と第一モーメントの対応は数学的恒等式—同 0）はドメインによって異なる現象—充足可能性（解の存在）、タスク正解率（機能的パフォーマン この枠組みは異なる認識論的地位を持つ三層に立脚する：

1. **数学**（無条件）：恒等式$e^{-\delta} = \prod_i p_i$および情報予算$\ln S = \ln N_{eff} + \ln(\mu/\mu_c) - \delta$は、$\delta = \sum_i(-\ln p_i)$という定義の代数的帰結である。これらは構成により成立する
2. **構造**（無条件）：第一モーメント$\mathbb{E}[\#\mathrm{SAT}] = 2^n \cdot e^{-\delta}$はランダムSATに対して正確であり—近似
$1 \implies \Pr[X \geq 1] = 0$）は充足可能性閾値の上界を与える。いずれのステップも解空間におけ
3. **精度**（ドメイン依存）：$\alpha_c^{(1)} \approx 5.19$と$\alpha_c \approx 4.27$の20%のギャップは、$\mathbb{E}[\#\mathrm{SAT}]$が間違っている
0である—指数的に多くの解を持つ稀なインスタンスが平均を引き上げている。これは割当間
SATを知ると近傍の$\tau \in \mathrm{SAT}$が予測される）であり、制約間の相関ではない。第二モーメント
Zygmund不等式）が相補的方向を与える：$\Pr[X > 0] \geq \mathbb{E}[X]^2/\mathbb{E}[X^2]$。重なり分解$\mathbb{E}[X^2] = 2^n \sum_d \binom{n}{d} g(d/n)^m$（$g(\beta) = 3/4 + (1/8)(1-\beta)^3$はペア相関関数）は閾値下界を与える。数値評価
4.51）。残りの26%は高次相関が必要である。ペア相関関数は$g(1/2)/(7/8)^2 = 1$を正確に満たし、典型的重なりの寄与は中立—ギャップは高相関ペア（$\beta \approx 0$）のみから生じる。各ドメインには固有のギャップがあり、第一モーメント予測と観測され

この三層構造は、独立性が何に影響し何に影響しないかを明確にする。第一モーメント上界は相関

SAT実験は構造化制約（XOR、含意鎖）で$R^2 > 0.99$、全3制約タイプで指数モデルがべき乗モ
δ交互作用を確認し、クッション機構を発見する。2つのドメインは相補的である：SATは厳密なδ
δ交互作用を検証するとともに、構造的矛盾が事実的ノイズと質的に異なることを明らかにする。

情報予算としての解釈。対数形式では、存続方程式は$\ln S = \ln N_{eff} + \ln(\mu/\mu_c) - \delta$となり、三項すべてがナット単位で測定される。これは任意の乗法方程式の対数を取っ
$-\ln p$、ナット）として定義されているため、$\ln N_{eff}$と$\ln(\mu/\mu_c)$が同じ単位を持つことは、真正な情
S_cは情報予算となる：情報容量（$\ln N_{eff} + \ln(\mu/\mu_c)$）が情報損失（$\delta$）を上回るとき、システムは存
nonの通信路符号化定理[26]との対応は、3つのレベルで厳密に定式化できる（§6.2）：(i) 独立制約
Lダイバージェンスに等しく、ギャップは第二モーメント比で支配される；(ii) XOR-SAT制約はパリティ検査そのものであり、制約充足と通信路符号化が同一の数学的対象となる；(ii
$\ln(N_{eff} \cdot \mu/\mu_c)$は通信路符号化定理$R < C$と構造的に同型であり、逆定理は無条件に成立し、達成可
$h(\beta) - \ln 2 + \alpha \ln R(\beta)$（$\varphi(1/2, \alpha) = 0$が全$\alpha$で成立）を含む枠組みと構造的性質はLean 4で形式的に

3項の認識論的地位。情報理論的基盤付けは3因子間で異なる。δについては、接続は厳密である
$-\ln p_i$は定義によりShannonの自己情報量であり、$e^{-\delta}$は第一モーメントである。$\ln N_{eff}$について
p_cが格子幾何学から定まり（2D三角格子で$p_c = 1/2$が厳密、3D単純立方格子で$p_c \approx 0.3116$が数値的に知られる [20]）、核安定性では臨界閾値がBethe–Weizsäcker質量公式から独立に

ドメイン間の測定非対称性。この領域依存性の根底には重要な非対称性がある。SATでは各制約
$-\ln(S_i/S_0)$—ため、δは入力と処理系の相互作用の性質となる。δの次元構造（制約タイプの重篤度
$I_{\text{structural}}$）は方程式に依存せず確認される（順序は方程式とは独立に観察可能であるため）。しか

クロスドメインの代替アプローチ。TruongとTruong [31]は独立に、フィードバック増幅が有限
enie, Westら[32]は環境摂動の変動性に対するシステム出力応答の凸性としてantifragilityを定量化し、交通管理、ロボット工学、腫瘍学にまたがって適用した。彼らの枠組みは

公理的導出の射程。§3.2の導出はドメイン非依存である：公理A1–A3（有限状態空間、割合除

6.2 情報理論的基盤付け

存続方程式と情報理論の接続は、共有語彙（ナット、自己情報量）を超えて、Shannonの定理群との間のギャップを閉じる3つの形式的結果に拡張される。結果1はLean 4の`Surviv`
0、`axiom` = 0）。

結果1：δ–KLダイバージェンス双対性。P_0を$\{0,1\}^n$上の一様分布、P_{SAT}を充足割当上の一様分布
$\ln(2^n/Z)$（$Z = |\text{SAT}|$）。独立制約（変数を共有しない）の場合、$Z = 2^n \cdot$
$\prod_i p_i = 2^n \cdot e^{-\delta}$が正確に成立するため、$D_{\text{KL}} = \delta$：累積情報損失は制約なし分布と制約付き分布のK-
Lダイバージェンスに等しい。一般には、Jensenの不等式（lnの凹性）により$\mathbb{E}[D_{\text{KL}}] =$
$n \ln 2 - \mathbb{E}[\ln Z] \geq n \ln 2 - \ln \mathbb{E}[Z] = \delta$が成立し、等号条件は$Z$が定数（分散0）のときかつそのときに
$\delta = \ln \mathbb{E}[Z] - \mathbb{E}[\ln Z]$は第二モーメント比$R_2 = \mathbb{E}[Z^2]/\mathbb{E}[Z]^2$により$\mathbb{E}[D_{\text{KL}}] -$
$\delta \approx (R_2 - 1)/2$と特性化される。これは既に確立された3つの結果を接続する：(a) 第一モーメントが

結果2：通信路符号化としての制約充足。XOR-SATでは接続が厳密である：各制約$x_{i_1} \oplus$
$x_{i_2} \oplus x_{i_3} = b_i$はGF(2)上のパリティ検査式であり、制約行列$H \in \text{GF}(2)^{m \times n}$は線形符号のパリティ検査
$Hx = b\}$を形成し$|\text{SAT}| = 2^{n - \text{rank}(H)}$、符号率は$R = 1 - m/n = 1 - \alpha$、各制約は正確に$\ln 2$ナットの情
$m \ln 2 = \delta$が（期待値ではなく）全インスタンスで成立する。充足可能性閾値$\alpha_c^{\text{XOR}} =$
1は$R = 0$に対応する。random 3-SATでは各節が$\ln(8/7) \approx 0.134$ナット（XORの$\ln 2 \approx$
0.693に対して）しか提供しないため、情報効率比$\ln 2/\ln(8/7) \approx 5.19$—第一モーメント閾値比およ

結果3：構造的容量定理。構造的容量$C_{\text{struct}} = \ln(N_{eff} \cdot \mu/\mu_c)$を定義する。存続条件$S \geq$
1は$\delta \leq C_{\text{struct}}$と等価であり、Shannonの通信路符号化定理（$R \leq C$）と構造的に同型である。Sha-
nonの定理の2方向にはそれぞれ直接の対応物がある：

- 逆定理（$\delta > C_{\text{struct}} \implies$ 崩壊）：第一モーメント法＋Markovの不等式により$\mathbb{E}[Z] <$
  $1 \implies \Pr[Z \geq 1] = 0$。無条件に成立。
- 達成可能性（$\delta < C_{\text{struct}} \implies$ 存続）：第二モーメント法（Paley–Zygmund）により$\Pr[Z >$
  $0] \geq \mathbb{E}[Z]^2/\mathbb{E}[Z^2]$。$R_2$が有界のとき正。XOR-SATでは$R_2 = 1$で完全一致；ran-
  dom 3-SATでは截断第二モーメントが$\alpha \approx 4.51$まで達成可能性を確立。

SATでの検証：$N_{eff} = 2^n$、$\mu/\mu_c = 1$とすると、$C_{\text{struct}} = n \ln 2$。第一モーメント閾値は$\delta_c^{(1)} =$
$\alpha_c^{(1)} \cdot n \cdot \ln(8/7) = n \ln 2 = C_{\text{struct}}$を正確に満たす。解釈は、制約からの累積情報損失が状態空間のエ
通信路符号化限界の有限次元・非線形一般化である。

6.3 コンテキストロットはδの蓄積である

実験35の実用的帰結を強調すべきである。一般に「コンテキストロット」と呼ばれる現象—
会話が長くなるにつれてLLMの性能が劣化する現象—は、従来、注意の希釈、位置エンコーディン

実験35はこの2変数を実験的に分離した。$\delta = 0$（構造矛盾ゼロ）の下では、4ベンダー5つの高
Claude内部トークン）まで完璧な正答率を維持する—劣化は一切ない。$\delta >$
0の下では、500トークンで即座に正答率が崩壊する。因果変数は矛盾の内容であり、系列の長さで

自然な会話では、コンテキスト長とδは交絡している：長い会話ほどユーザーの訂正（「さっき

この再定式化は実用的含意を持つ：

従来のアプローチ	**δに基づくアプローチ**
コンテキスト窓を拡大	蓄積した矛盾を除去
要約して圧縮	矛盾のない要約を保証
RAG：関連チャンクを取得	取得チャンク間の整合性を検証

この区別は検証可能である：コンテキストロットが主にδ駆動であるならば、コンテキストから矛盾
$0) = \mu$（表 10）は、そのような介入を測定するためのベースラインを提供する。注目すべきことに
Sonnet 4.6は128,000トークンにおいて$\delta > 0$下でも注入された矛盾を試行の100%で検出・拒絶し

指数関数形式に対する独立した支持がWangとSun [34]から得られている。彼らはLLM作業記憶
数学的に$S \propto e^{-k \cdot \text{interference}}$と等価である。彼らの干渉変数（意味的類似性ベースの蓄積）は我々の

6.4 確立されていないこと

適用範囲：構造的矛盾 vs. ランダムノイズ。モデルは、摂動が構造的矛盾—構成要素間の論理的、

性質	構造的矛盾	ランダムノイズ
δの性質	制約矛盾	確率的劣化
関数形式	指数（$e^{-\alpha\delta}$）	べき乗則/臨界
例	SAT、LLM、組織	パーコレーション、RMT
存続モデル	本来の適用域	対照比較（フィットするが機構が異なる）

この区別は実験的に検証される：指数減衰（構造化制約で$R^2 > 0.99$、全3タイプで指数モデルが

レベルB予測は実証されていない。この枠組みはδがプロキシ測定を必要とするドメインにおいて

$e^{-\delta}$と$(1-\delta)$の弁別はLLMでは弱い。低δ領域では$e^{-\delta} \approx 1-\delta$であり、LLM実験はステップ関数的
0.99；表1）。3Dパーコレーションテストは高δ領域で指数形式にわずかな優位性を示す（ΔAUC =
+0.015）。2ドメイン設計が不可欠である：SATがLLM単独では不可能な関数形式の弁別を提供す
この貢献は$e^{-\delta}$と$1-\delta$の区別を必要としない。

6.5 適用範囲の境界：構造的矛盾 vs. ランダム除去

適用範囲を定義する対照として、パーコレーション（格子上のランダムサイト除去）は集約レベル
$= 0.993$、3Dで0.982）が、根本的に異なるメカニズム—構造的矛盾ではなくランダム除去—で動作

6.6 座標としてのδの射程

姉妹研究[Sunagawa, 2026]は、同じ構造パラメータδがSATソルバーの計算コストも支配すること
$e^{c\delta}$とスケールし、感度指数cはソルバー依存である（CDCL: $c \approx 0.24$、Walk-
SAT: $c \approx 0.21$、ランダム探索: $c = 1.0$（厳密））。この研究から得られた2つの知見は、本枠組みに
$e^{c\delta}$はμ_c自体がδの関数であることを意味し、静的方程式が独立として扱うμ/μ_c因子と$e^{-\delta}$因子の間に
$\alpha n|\ln(7/8)|$は問題サイズnの方向には対称的に拡張されない：CDCLランタイムはαとnの両方向に

6.7 ドメイン横断δプロキシの見取り図

本稿で検証された2つのレベルAドメインにおけるδ測定の形態を表11に示す。

レベルBドメイン（珊瑚白化、企業倒産、遺伝子保存、金融市場）における探索的プロキシ試行
Heating Weeks、ガバナンスイベント）は瞬間的状態（例：イールドカーブ、キーワード頻度）を

[8]具体的な探索結果：珊瑚白化でDegree-Heating Weeksをδプロキシとした場合$R^2 =$
0.957；企業倒産でガバナンスイベント（AUC = 0.74）対キーワード頻度（AUC

ドメイン	δの定義	自由パラメータ	認識論的地位
SAT	第一モーメント（$\sum_i I(C_i)$）	0	数学的恒等式
LLM	操作的（制約注入）	≥ 2	構造的類推

Table 11: 検証済みドメインにおけるδ測定。SATではδは問題構造から自由パラメータなしで計算可

6.8 適用可能性条件：精度とスコープの区別

公理A1–A3は$e^{-\delta}$の数学的導出を保証するが、それらは精度の条件であって適用可能性の条件では

真の適用可能性条件はA1–A3の上流に位置する：対象システムが、環境変化に対して最適化が

スクリーニングの完全な階層は以下の通りである：(0) 最適化が環境変化に追いついていないか
(1) 制約を状態空間と独立に定義できるか？ (2) 自然なモジュール境界が存在するか？
(3) A3はどの程度成立するか？ 段階0–1が枠組みの適用可能性そのものを決定し、段階2–3が予測精

6.9 今後の方向性

レベルBドメイン。この枠組みは制約処理システムに対する検証可能な予測を生成する：候補δプロ

レジーム遷移。安定条件下で十分に最適化されたシステムでも、環境変化の速さが適応の速さを

動的モデル。静的方程式$S = N_{eff} \cdot (\mu/\mu_c) \cdot e^{-\delta}$はスナップショットを記述する。崩壊までの時間を
$-(\delta/N_{eff}) \cdot \mu$は理論的段階に留まる。検証には$\delta$、$N_{eff}$、$\mu$の同時縦断測定を伴う時系列データが必

収束維持。本論文で文書化した崩壊現象には自然な双対がある：$\delta = 0$の系は、任意のコンテキ
収束維持を条件$D_{\mathrm{KL}}(P(y|x,\delta) \| P(y|x,0)) \leq \varepsilon$として定義する（$P(y|x,0)$は構造矛盾ゼロでの出力分布
D_{KL}恒等式（結果1）と自然に接続する：入力側の構造矛盾と出力側の劣化が同一の情報理論的通貨
0の場合を確認した：4ベンダー5つの高能力モデル（GPT-4o-mini、Gemini 2.5 Flash、Gemini 3.1 Flash Lite、Claude Sonnet 4、Claude Sonnet 4.6）が$\delta = 0$下で128,000トークンまでの全テスト済みコンテキスト長にわたり100%の正答率
0は即座に劣化を引き起こした。低μモデル（Llama 3.1:8b）は$\delta = 0$でも36%に留まり、収束維持が
schitz連続性条件の体系的検証は今後の課題である。

7 限界

1. **新規の数学的結果はない**：この枠組みは既存の数学的構造（第一モーメント法、直列信頼性、

2. **SATの範囲**：第一モーメント$\mathbb{E}[\#\mathrm{SAT}] = 2^n \cdot e^{-\delta}$は正確であり、閾値上界は無条件に妥当である
5.19）と真の閾値（$\alpha_c \approx 4.27$）の20%のギャップがこの精度損失を定量化する。第二モーメン
4.51を与え、ギャップの74%を説明する。残りの26%（4.51対4.27）はレプリカ対称性の破れ
18–28、総当たり列挙）にわたり平均5.04×、CV = 5.0%で確認されており、第一モーメント上

3. **LLM予測は事前登録されていない**：5つの理論導出予測（表9）は方程式の構造から従い実験

$\approx$ 0.50）；遺伝子保存でPPI度をN_{eff}とした場合ΔAIC $<$
-500対パラログ数（失敗）。これらの結果はデータリポジトリで公開されているが、本稿の主張ではない。

4. **μ_cは本枠組み内で導出されない**：存続方程式はμ_cの役割（機能維持に必要な最小資源流量）を
maが質量mを導出しないのと同じ構造である。μ_cの導出可能性はドメイン固有の独立理論の
p_cが格子幾何学から導出され（自由パラメータゼロ）、核安定性では半経験的質量公式が臨界
14–16）はμを固定しδのみを操作する設計であり、存続比$S(\delta)/S(0) =$
$e^{-\delta}$の検証としてμ_cの値に依存しない。旧ヒューリスティック$\mu_c = 1/(2N_{eff})$は導出に基づかな

5. **レベルB予測**：この枠組みはいかなるレベルBドメイン（生物・組織・生態系）でも検証され

6. **3因子は網羅的でない可能性がある**：N_{eff}、μ/μ_c、δへの分解は関連因子を省略している可能

7. **形式検証の範囲**：Lean 4検証（16モジュール）は数学的性質（代数的整合性、定理の妥当性
Zygmund第二モーメント不等式、およびペア相関構造を対象としており、経験的正しさは対

8. **$\delta = 0$不変性はタスク依存**：Duら[35]は、完璧な検索・矛盾ゼロの条件下でも、コンテキスト
0精度を見出しているが、タスク（矛盾検知を伴う3変数演算）は多段階推論タスクに比べて
$\mu(L)$を通じてこれを許容する：ベースライン能力が長さとともに劣化するタスクでは、$\delta =$
0はもはや完璧な精度を保証しないが、依然として天井を設定する。δ駆動劣化が長さ駆動劣化

9. **反証可能性**：モデルは2つのレベルで反証可能である。構造的反証：SAT減衰率比が大きなn
δ交互作用が再現されない場合；またはδが厳密に計算可能な新しいレベルAドメインにおいて

8 結論

構造的矛盾下でのLLM推論崩壊が、特定の再現可能なパターン—乗法的$\mu\times$
δ交互作用、δにおける次元構造、クロスモデル収束を伴うクッション機構—を示し、これらが組合
$N_{eff}\cdot(\mu/\mu_c)\cdot e^{-\delta}$（$\delta = \sum_i I(\text{constraint}_i)$は累積情報損失、ナット単位）はこれらのパターンを捉え
$5.19\times$、5.04 ± 0.25で確認）。

2つの制御されたドメインで確認：

- **SAT**：指数ペナルティ$e^{-\delta}$はSAT解の個数の第一モーメントと数学的に同一である。3種類の制
0.98）。パラメータフリー比率$\alpha_{\text{XOR}}/\alpha_{\text{random}} = 5.19\times$は6つのシステムサイズにわたり安定（C
$= 5\%$）。

- **LLM**：乗法的$\mu\times\delta$交互作用—個別には致死的でない2因子が組み合わさると致死的になる（加
δ_{factual}）。RLHFクッション機構が矛盾を圧倒されるまで吸収し、システム固有の臨界閾値δ_c

- **形式検証**：存続選択定理$d\langle\delta\rangle/dt = -\text{Cov}(\delta, h) < 0$、公理から指数形式への導出（A1–A3
$\Rightarrow e^{-\delta}$）、Cauchy一意性、Paley-Zygmund第二モーメント不等式、および閾値下界のための
0、`axiom` $= 0$）。

未確認：

- レベルBの定量的予測：プロキシδ測定を必要とするドメインにおける検証済み予測はない

- 動的モデル（$d\mu/dt = -(\delta/N_{eff})\cdot\mu$）：未検証

- 低δ領域での$e^{-\delta}$と$(1-\delta)$の弁別（これらの形式が収束する領域）

この枠組みは新規の数学的結果を導入しない。その貢献は操作的方法論である：構造的矛盾を
SATが数学的恒等式を検証し、LLMが乗法的交互作用を検証するとともに、制約の質が量ではなく

データとコードの公開

- Lean 4形式化：`https://codeberg.org/delta-survival/papers/src/branch/main/lean`
- SAT実験：`analysis/sat/`
- LLM実験：`analysis/llm/`
- 第二モーメントギャップ分析：`analysis/sat/second_moment_gap_analysis.py`

謝辞

本稿の初期原稿に対し、詳細かつ建設的なコメントをいただいた井川一樹氏に感謝いたします。

References

[1] Achlioptas, D. (2009). Random satisfiability. In Handbook of Satisfiability, pp. 245–270. IOS Press.

[2] Alon, N. & Spencer, J.H. (2016). The Probabilistic Method, 4th ed. Wiley.

[3] Berglund, L. et al. (2023). The Reversal Curse: LLMs trained on “A is B” fail to learn “B is A”. arXiv:2309.12288.

[4] Aczél, J. (1966). Lectures on Functional Equations and Their Applications. Academic Press.

[5] Barlow, R.E. & Proschan, F. (1975). Statistical Theory of Reliability and Life Testing. Holt, Rinehart and Winston.

[6] Ben-Sasson, E. & Wigderson, A. (2001). Short proofs are narrow—resolution made simple. J. ACM, 48(2), 149–169.

[7] Cocco, S. & Monasson, R. (2001). Trajectories in phase diagrams, growth processes, and computational complexity: How search algorithms solve the 3-satisfiability problem. Physical Review Letters, 86(8), 1654–1657.

[8] Cover, T.M. & Thomas, J.A. (2006). Elements of Information Theory, 2nd ed. Wiley.

[9] Cox, D.R. (1972). Regression models and life-tables. J. Royal Statistical Society B, 34(2), 187–220.

[10] Duderstadt, J.J. & Hamilton, L.J. (1976). Nuclear Reactor Analysis. Wiley.

[11] de Moura, L. & Ullrich, S. (2021). The Lean 4 theorem prover and programming language. CADE-28, LNCS 12699, 625–635.

[12] Dziri, N. et al. (2023). Faith and Fate: Limits of Transformers on Compositionality. NeurIPS 2023.

[13] Eigen, M. (1971). Self-organization of matter and the evolution of biological macromolecules. Naturwissenschaften, 58(10), 465–523.

[14] Fisher, R.A. (1930). The Genetical Theory of Natural Selection. Clarendon Press.

[15] Friedgut, E. (1999). Sharp thresholds of graph properties, and the k-SAT problem. J. American Mathematical Society, 12(4), 1017–1054.

[16] Giannakopoulos, B. (2025). Persistence Theory and the Persistence Equation. OSF Preprints.

[17] Kaplan, E.L. & Meier, P. (1958). Nonparametric estimation from incomplete observations. J. American Statistical Association, 53(282), 457–481.

[18] Liu, N.F. et al. (2024). Lost in the Middle: How language models use long contexts. Transactions of the ACL, 12, 157–173.

[19] May, R.M. (1972). Will a large complex system be stable? Nature, 238, 413–414.

[20] Mertens, S. & Moore, C. (2018). Percolation thresholds and Fisher exponents in hypercubic lattices. Physical Review E, 98(2), 022120.

[21] Mézard, M., Parisi, G., & Zecchina, R. (2002). Analytic and algorithmic solution of random satisfiability problems. Science, 297, 812–815.

[22] Ouyang, L. et al. (2022). Training language models to follow instructions with human feedback. NeurIPS 2022.

[23] Price, G.R. (1970). Selection and covariance. Nature, 227, 520–521.

[24] Prigogine, I. & Stengers, I. (1984). Order Out of Chaos. Bantam Books.

[25] Scheffer, M. et al. (2009). Early-warning signals for critical transitions. Nature, 461, 53–59.

[26] Shannon, C.E. (1948). A mathematical theory of communication. Bell System Technical Journal, 27, 379–423.

[27] Wei, J. et al. (2022). Chain-of-thought prompting elicits reasoning in large language models. NeurIPS 2022.

[28] Zhang, X., Zhang, Y., Chen, Z., Yu, J., Yang, W. & Song, Z. (2026). Logical phase transitions: Understanding collapse in LLM logical reasoning. arXiv preprint arXiv:2601.02902.

[Sunagawa, 2026] Sunagawa, A. (2026). Predicting computational cost from the structural parameter δ: Separating existence from discovery in random 3-SAT. Preprint.

[Cantor & Packer, 1996] Cantor, R., Packer, F. (1996). Determinants and impact of sovereign credit ratings. Federal Reserve Bank of New York Economic Policy Review, 2(2), 37–54.

[29] Shumailov, I., Shumaylov, Z., Zhao, Y., Papernot, N., Anderson, R. & Gal, Y. (2024). AI models collapse when trained on recursively generated data. Nature, 631, 755–759.

[30] Parsons, J., McCoy, R.T., Garrette, D., Linzen, T. & Bowman, S.R. (2025). The Illusion of Thinking: Understanding the strengths and limitations of reasoning models via the lens of problem complexity. Apple Machine Learning Research.

[31] Truong, N.B. & Truong, Q.-T. (2025). Entropy Collapse: A universal failure mode of intelligent systems. arXiv preprint arXiv:2512.12381.

[32] Axenie, C., West, R. et al. (2024). Antifragility in complex dynamical systems. npj Complexity, 1, 5.

[33] Hong, K., Troynikov, A. & Huber, J. (2025). Context Rot: How Increasing Input Tokens Impacts LLM Performance. Chroma Research, July 2025.

[34] Wang, C. & Sun, J.V. (2025). Unable to Forget: Proactive Interference Reveals Working Memory Limits in LLMs Beyond Context Length. arXiv preprint arXiv:2506.08184.

[35] Du, Y., Tian, M. et al. (2025). Context Length Alone Hurts LLM Performance Despite Perfect Retrieval. EMNLP 2025 Findings.

[36] Xu, R., Qi, Z., Guo, Z. et al. (2024). Knowledge Conflicts for LLMs: A Survey. EMNLP 2024.

[37] Zheng, X., Huang, Z. et al. (2025). KCR: Resolving Long-Context Knowledge Conflicts via Reasoning in LLMs. arXiv preprint arXiv:2508.01273.

[38] Jiao, D., Wang, D. & Hu, L. (2026). Understanding the Dynamics of Demonstration Conflict in In-Context Learning. arXiv preprint arXiv:2603.04464.