論理一貫性維持の構造持続的記述

— 推論経路の縮小と最初の実験 —

Akihito Sunagawa

2026年4月

要旨

本稿は、大規模言語モデルにおける論理一貫性維持を、構造持続の最小形式 [1] の最初の具体例として記述することを目的とする。観測量 Y を、与えられた論理課題に対して、モデルが自己矛盾なく、与えられた規則や前提に反しない形で推論を完了できたかどうかとして独立に定義する。そのうえで、論理一貫性を保って推論を完了しうる候補経路の集合を置き、制約の蓄積をその集合の逐次縮小として表す。各段階の縮小率を対数で表すと、有効経路の残り方は指数型で記述される。ただし、本稿で直接に主張するのは、この指数型の上界そのものではなく、観測に使う指標 z が増えるにつれて論理一貫性維持率 Y が平均傾向として悪化する、という弱い命題である。この主張は、構造を保てたならそのための経路が必要であるという概念的前提、観測指標が経路の残り方を反映するという経験的前提、制約が縮小方向に働くという前提のもとで導かれる。さらに、範囲づけあり更新と範囲づけなし更新の比較を中心実験として提案し、この方向を検証する。

1　はじめに

本稿の問いは、大規模言語モデルにおける論理一貫性の維持を、構造持続の問題として記述できるか、である。

ここでいう論理一貫性維持とは、単なる正答率の問題ではない。重要なのは、与えられた前提や規則のもとで、自己矛盾なく推論を最後まで完了できるかどうかである。崩れとは、単に誤答が出ることではなく、そのために必要な推論の道筋が減少し、その結果として一貫した推論を安定して維持できなくなることを指す。

本稿の目的は、この事態を最小形式で記述することである。ここで中心に置くのは、論理一貫性の成否を直接に説明することではなく、論理一貫性を保てる推論経路の集合が、制約の蓄積によってどのように縮小するかを表すことである。そのうえで、観測される論理一貫性維持率との関係を、仮定を明示した弱い命題として位置づける。

2　観測量の定義

観測量 Y を次のように定義する。

$Y = 1$　与えられた論理課題に対し、モデルが自己矛盾なく、
　　与えられた規則や前提に反しない形で推論を完了できた。

$Y = 0$　それができなかった。

重要なのは、Y を先に独立の観測量として定義することである。有効経路の集合を用いて Y を定義してはならない。さもなければ、後に与える理論構成が循環するからである。

3　候補推論経路と有効経路

ある論理課題に対して、モデルが取りうる候補推論経路の全体を $\mathcal{P}$ とする。最初の段階では、経路の細かさを次のような粗い単位で固定する。

1. 前提を選ぶ
2. 規則を適用する
3. 中間結論を出す
4. 最終結論を出す

したがって、$\mathcal{P}$ は離散的な推論段階列の集合として扱う。トークン単位の内部過程までは、ここでは立ち入らない。

制約が加わる前に、論理一貫性を保って最後まで到達しうる候補経路の集合を $A^{(0)}$ とする。$A^{(0)}$ は、前提を落とさず、規則に反せず、中間段階で自己矛盾を起こさず、最終結論まで到達できるような推論段階列の集合である。

ここでも、$A^{(0)}$ を Y そのもので定義しないことが重要である。$A^{(0)}$ はあくまで、論理一貫性を達成しうる候補経路の構成的集合として置かれる。本稿で導入する有効経路集合は理論構成物であり、その直接観測を主張しない。経験的内容は、事前に定めた代理指標が基準モデルに対して追加予測力を持つかどうかにかかる。

4　制約と縮小

論理一貫性を崩しうる制約として、少なくとも次を考える。

1. **構造的な矛盾** — 前提や規則そのものが互いに衝突する。
2. **指示の衝突** — 「こう答えよ」と「こう答えるな」が競合する。
3. **時間的な不整合** — 古い規則と新しい規則が整理されずに混在する。
4. **参照元どうしの衝突** — 参照元ごとに異なる規則や事実が未整理で共存する。
5. **未整理の上書き** — 新しい情報が古い情報を条件づけなしに上書きする。

本稿では、これらの制約は、有効経路の集合に作用し、その集合を縮小させるものとして扱う。したがって、制約が順に加わると、

$$A^{(0)} \supseteq A^{(1)} \supseteq \cdots \supseteq A^{(n)} \tag{1}$$

という包含列が得られると仮定する。

5　経路集合の縮小を表す補題

制約が順に加わるたびに、有効経路の集合が $A^{(0)}, A^{(1)}, \ldots, A^{(n)}$ と縮小していくとする。各段階の縮小率を

$$p_i = \frac{m(A^{(i)})}{m(A^{(i-1)})}$$

とおく。ここで m は最小形式 [1]における測度に対応する量であり、最初の段階では候補推論経路を一様に数える素朴な測り方を仮置きする。

補題 5.1. 累積損失を $L = \sum[-\log p_i]$ と置けば、

$$m(A^{(n)}) = m(A^{(0)})\, e^{-L} \tag{2}$$

が成り立つ。

この補題が示しているのは、制約が有効経路を順に削るなら、その残り方は累積損失 L に対して指数型で書ける、ということである。

ただし、この段階では観測量 Y との関係はまだ主張しない。したがって、ここでの指数型はあくまで経路集合の縮小に関する形式的結果であり、最小形式（[1], 命題 1）の本設定への適用である。本稿では単調性の検証にとどまるが、この指数型は、将来の定量的予測——たとえば制約の種類ごとの減衰率の比較——への接続点として置かれている。

6　三つの前提

本稿では、経路集合の縮小と観測量 Y とを結ぶために、次の三つの前提を置く。

仮定 A（経路の必要性） 構造を保てたなら、そのための経路が必要である。すなわち、$Y = 1$ が成立するならば、その出力過程は少なくとも一つ、論理一貫性を保てる経路を通っている。これは概念的な前提である。

仮定 B（指標の単調反映） 観測に使う指標 z は、有効経路の残り方を単調に反映する。たとえば、z が大きくなるほど、有効経路の残りは小さくなる、あるいは少なくともその傾向を持つと考える。候補となる指標としては、明示的な矛盾の数、未整理の上書きの数、範囲づけされていない衝突の数、指示の衝突数、参照元どうしの不整合密度などがある。これは経験的な前提である。

仮定 C（制約の縮小方向性） 制約は縮小方向に働く。すなわち、各制約は、有効経路の集合を広げることはなく、縮めるか、そのままに保つ。

7　弱い命題

仮定 A のもとでは、観測される論理一貫性維持率 Y は、有効経路の残り方によって制約されると考えられる。

ただし、本稿で直接に検証したいのは、この上界そのものではない。本稿の中心に置くのは、次の弱い命題である。

主たる命題. 観測に使う指標 z が増えるにつれて、論理一貫性維持率 Y は平均傾向として悪化する。

ここで重要なのは、この主張が強い完全特徴づけではないことである。本稿で与えるのは、経路集合の縮小という構造的記述と、観測量 Y の悪化方向とをつなぐ最初の弱い関係である。本稿の実質的主張は、仮定 B の妥当性にかかっている。すなわち、z が有効経路の残り方を反映する操作的な代理指標として機能するかどうかが、この命題の経験的内容を決定する。

8　指標間の強弱についての予測

すべての指標が同じ強さで効くとは限らない。機構的には、次の予測が成り立つ。

- 構造的な矛盾は、前提や規則の両立可能性そのものを壊すため、有効経路を広く一気に縮小させやすい。
- 単なる事実の衝突は、局所的な選択の競合にとどまる場合があり、経路削減は相対的に小さいことがある。
- 範囲づけのない上書きは、古い規則と新しい規則を同一平面で衝突させるため、複数の経路を同時に不安定化しやすい。
- 時間や条件で整理された更新は、分岐として保持できるため、経路削減を抑えやすい。

本稿では、この予測を補助命題として位置づける。

補助命題. 制約の質によって、論理一貫性維持率 Y への効き方は異なる。とくに、構造的矛盾は事実的衝突よりも広く有効経路を削り、Y をより強く悪化させる。

この補助命題は、最小形式の含意——制約の質は量に優先しうる——に動機づけられた経験的予測である。最小形式は、制約ごとの縮小率 p_i が異なりうることを許すが、どの制約型が大きな縮小を生むかは個別領域に依存する。したがって、補助命題の理論的導出は今後の課題であり、本稿ではこれを経験的に検証すべき予測として位置づける。

予備的な観測として、30ターン対話実験（別稿）では、代謝介入の有無によるカテゴリ別の効果が次のように観測されている（表 1）。

Table 1: 代謝介入の有無によるカテゴリ別効果（gemma4:31b, $n = 3$, 30ターン, rejudge 済み）

カテゴリ	代謝あり	代謝なし	差
矛盾検出	67%	7%	+60pt
規則適用	53%	40%	+13pt
事実再現	47%	40%	+7pt

効果の大きさは矛盾検出 ≫ 規則適用 > 事実再現の順であり、補助命題の予測と整合する。ただし、これは単一モデルでの事後的観測であり、本稿の中心実験による検証とは区別される。

なお、別モデル（qwen3.5:27b）での同様の実験では、矛盾検出の代謝効果（ON–OFF 差 0pt）が消失し、規則適用では代謝あり条件がむしろ劣位（–6.7pt）となった。分析の結果、この逆転には二つの要因が寄与している。第一に、代謝パイプラインが抽象的一貫性を優先して具体的更新値を落とす失敗モード（abstraction drift）である。第二に、代謝パイプラインに用いる LLM の質がボトルネックになりうることが、後続実験（contra audit smoke, 2026-04-11）で判明した。同一の対話 LLM（qwen3.5:9b）に対して代謝 LLM を高能力モデル（Claude Sonnet）に切り替えたところ、矛盾検出が回復した。したがって、補助命題の順序は、代謝機構が具体更新を忠実に保持できること、および代謝 LLM の質が十分であることを暗黙に前提しており、いずれかの前提が崩れるとき順序は不成立になりうる。補助命題の成立条件の精緻化は今後の課題である。

9　実験の位置づけと中心実験

実験は二つの役割を持つ。第一に、指標 z と Y の単調関係を確かめること。第二に、この設定では z が有効経路の残り方を反映する指標として妥当であることを支持することである。

中心実験として、本稿では「範囲づけあり更新」と「範囲づけなし更新」の比較を置く。

目的.　未整理の上書きが論理一貫性をどの程度強く崩すかを直接に見る。

条件.

- 古い規則と新しい規則を与える。
- 一方は時間・条件ラベルありで整理する（代謝あり条件）。
- 他方はラベルなしで混在させる（代謝なし条件）。

評価.　論理一貫性維持率（規則適用・矛盾検出）、知識検索の可用性（検索成功率）。

予測.　範囲づけあり更新のほうが Y を保つ。範囲づけなし更新は、より強く Y を悪化させる。

この実験は、仮定 B の最小検査系として設計されている。すなわち、z（未整理の上書き数）が有効経路の残り方を反映する操作的な代理指標として機能するかどうかを、最も明瞭な設定で検証する。

9.1　実験 1: 30ターン対話実験（範囲づけの有無）

外部代謝パイプラインを組み込んだ対話系において、矛盾を含む30ターンの対話を実施し、代謝あり（範囲づけあり更新）と代謝なし（範囲づけなし上書き）を比較した。代

謝あり条件では、矛盾する情報が時間ラベルつきの対として整理・保持される。代謝なし条件では、矛盾する情報が整理されずに蓄積される。

結果を表 2に示す。

Table 2: 実験 1 結果（gemma4:31b, $n = 3$ trials, 30ターン, rejudge 済み）

カテゴリ	代謝あり	代謝なし	差
規則適用	53%	40%	+13pt
矛盾検出	67%	7%	+60pt
検索成功率	67%	0%	+67pt

代謝あり条件はすべての指標で代謝なしを上回る。とくに検索成功率は、代謝なし条件で完全に失われる（0%）のに対し、代謝あり条件では 67% を維持しており、範囲づけの有無が知識の検索可能性に直接作用していることを示す。これは予測と整合する。

9.2 実験 2: 100ターン長期安定性実験

30ターンを超えて制約が蓄積する場合に、論理一貫性維持率が経時的に悪化するかを検証した。代謝あり条件で100ターンの対話を実施し、10ターンごとにベンチマークを投入した。

結果を表 3に示す。

Table 3: 実験 2 結果（qwen3.5:9b, 代謝あり条件, 1 trial, 100ターン）

ターン	規則適用	矛盾検出	検索成功率
T10	100%	100%	96%
T20	93%	100%	96%
T30	100%	93%	96%
T40	93%	100%	96%
T50	100%	100%	96%
T60	100%	100%	96%
T70	87%	93%	96%
T80	100%	87%	96%
T90	100%	100%	96%
T100	93%	93%	96%

規則適用と矛盾検出は 87–100% の範囲で振動し、単調な劣化は観測されなかった。検索成功率は 96% で 10回連続不変であった。

この結果は弱い命題の棄却を意味しない。代謝あり条件は範囲づけあり更新に相当し、制約の蓄積を代謝が逐次解消しているため、実効的な z の蓄積が抑えられている。弱い命題は「z が増えるにつれて Y が悪化する」と述べるが、代謝によって z の増加自体が抑制されている条件では、Y の安定は予測と整合する。

9.3 解釈

実験 1 は、範囲づけの有無が論理一貫性維持率に強い影響を与えることを示している。とくに矛盾検出における +60pt の差は、構造的矛盾への介入効果が事実的再現よりも大きいという補助命題の方向と整合する。

実験 2 は、代謝（範囲づけ）が機能し続ける限り、100ターンの制約蓄積のもとでも論理一貫性は崩壊しないことを示している。これは、z の蓄積を抑える介入が Y の維持に有効であることを間接的に支持する。

ただし、これらの結果には次の限界がある。第一に、代謝なし条件の100ターン実験はまだ実施されていない。第二に、実験 1 は単一モデル（gemma4:31b）での観測であり、別モデル（qwen3.5:27b）では補助命題の順序が崩れることが確認されている（第 8節参照）。第三に、検索成功率は代謝の有効性を示すが、事実再現率は別の障壁（応答生成層の問題）によって低水準にとどまっており、論理一貫性維持率のすべてが範囲づけだけで決まるわけではない。

第 10節で挙げた他の指標候補（構造的矛盾の数、指示の衝突数、参照元間の不整合密度など）に対する体系的検証は、今後の課題として残る。

10 限界

本稿は、大規模言語モデル全般が完全にこの数学に乗ると主張するものではない。また、下界まで含めた完全な特徴づけを与えるものでもない。さらに、ここで仮置きした経路の測り方が最終形であるとも主張しない。本稿で置く推論経路の集合は理論構成物であり、モデル内部の実際の計算過程との一対一対応を主張するものではない。本稿の経路概念は、内部機構の同定ではなく、論理一貫性維持を議論するための粗視化された過程モデルとして位置づけられる。

本稿が与えるのは、より限定された主張である。すなわち、論理一貫性維持を独立に定義し、有効経路の集合を構成的に置き、制約の蓄積をその縮小として表すならば、その残り方は指数型で書ける。そして、仮定 A・B・C のもとで、観測量 Y の悪化方向について弱い命題を与えることができる、ということである。

11 結論

本稿では、大規模言語モデルにおける論理一貫性維持を、構造持続の最初の具体例として記述した。論理一貫性を保てる推論経路の集合を置き、制約の蓄積をその縮小として表すと、有効経路の残り方は累積損失に対して指数型で記述される。そのうえで、構造を保てたならそのための経路が必要であること、観測指標が経路の残り方を反映すること、制約が縮小方向に働くことを前提すれば、観測される論理一貫性維持率は指標の増加にともなって悪化すると予想される。

本稿の役割は、この方向を最初の具体例として明示することにある。最初の実験の役割は、この弱い命題を支持し、同時に観測指標の妥当性を示すことである。

References

[1] Sunagawa, A. 構造持続の最小形式. 2026.

[2] Sunagawa, A. 構造持続の条件つき導出. 2026.

[3] Sunagawa, A. 前提更新を伴う継続学習における構造的忘却. 2026.

[4] Sunagawa, A. 持続知能の混成構成. 2026.