# 前提更新を伴う継続学習における構造的忘却

— 多アダプタ LoRA による分離とその限界 —

Akihito Sunagawa

2026年4月

**要旨**

逐次的な知識更新を受ける大規模言語モデルでは、破滅的忘却が繰り返し観測される。しかし、すべての忘却が同じではない。新しい事実が既存の前提を覆すとき、単一の事実だけでなく、その前提に依存していた派生知識も同時に無効化され、再構成されなければならない。本稿では、この種の忘却を前提更新依存的な構造的忘却として捉える。

そのために、本稿では明示的な前提–帰結依存を持つ合成ベンチマークを構成し、逐次タスクのもとで三つの LoRA 条件を比較する。第一は再提示ベースの E-lite、第二は前提 DAG を用いて依存知識を選択的に再提示する F-v2c、第三は現在知識と過去知識を別アダプタに分離する F-multi である。7 モデル・4 系統の比較により、次の結果を得る。第一に、テストした全条件・全系統で、最初の前提更新以降に T2 collapse が一貫して現れ、LoRA は蓄積ではなく上書きとして振る舞う。第二に、F-v2c は後半タスクの依存整合性を改善し、単純な再提示だけでは到達できない水準に安定的に到達する。第三に、F-multi は旧タスク保持を初めて非ゼロにし、保持と更新の単純なトレードオフを部分的に破る。第四に、それでも保持アダプタの絶対性能は低く、パラメータ水準での保存には限界がある。

本稿の主張は、LoRA ベース継続学習が無効だということではない。主張は、前提更新を伴う知識更新において、本実験条件ではパラメータ的な更新だけでは高忠実度の長期保持を達成しにくいということである。多アダプタ分離は一定の救済を与えるが、それは長期的な知識整合性の維持の十分条件ではない。

## 1　はじめに

長期的に運用される大規模言語モデルは、新しい事実を逐次的に学習し続けなければならない。ユーザの住所が変わる、企業の本社が移転する、制度が改定される、科学的知見が更新される。このときモデルは、単に新しい事実を加えるだけでは足りない。ある更新が既存の前提を覆すなら、その前提に依存していた知識の連鎖も同時に更新されなければならない。

この点で、前提更新を伴う継続学習は、通常の知識追加と異なる。たとえば「会社 X の本社は東京である」が「会社 X の本社は大阪である」に更新されたなら、最寄駅、通勤路線、オフィス街、配送区域といった派生知識も一斉に更新されるべきである。古い本社と新しい最寄駅を同時に保持してしまう系は、単に古い知識を忘れたのではなく、内部的に不整合である。

この論文の問いは、LoRA ベースの継続学習が、この種の前提更新をどこまで扱えるか、である。より具体的には、LoRA は知識を積み上げるのか、それとも新しい更新によって古い表現を上書きするのか。また、前提依存を明示的に制御する再提示や、複数アダプタへの空間分離は、この問題をどこまで救えるのか。

本稿では、前提–帰結依存を明示した合成ベンチマークを構築し、E-lite、F-v2c、F-multi の三条件を比較する。その結果、本実験条件では LoRA は上書き的に振る舞い、前提認識制御器と多アダプタ分離はそれを部分的に緩和するが、高忠実度の長期保持にはなお限界が残ることを示す。

# 2　問題設定

## 2.1　前提更新依存的忘却

本稿では、ある更新が既存の前提を覆し、その前提に依存する派生知識の再構成を必要とする状況を前提更新依存的忘却と呼ぶ。これは単なる忘却ではない。保持すべきなのは、古い知識そのものではなく、現在有効な前提に対して整合した知識構造である。

本稿では、このような前提更新にともなって依存知識の連鎖が崩れる忘却を、構造的忘却と呼ぶ。ここでいう構造的忘却とは、単一の事実の喪失ではなく、依存構造ごと崩れる忘却を指す。

したがって、評価すべきなのは旧タスクの保持だけではない。新しい前提の導入後に、派生知識がどれだけ一貫して更新されるか、すなわち依存整合性が同時に問われる。

## 2.2　研究課題

本稿では、次の三点を問う。

1. LoRA ベース継続学習は、前提更新を受けたときに知識を蓄積するのか、それとも上書きするのか。
2. 前提認識型の再提示は、単純な再提示よりも派生知識の整合性を改善するか。
3. 多アダプタ分離は、保持と更新の衝突を緩和できるか。

# 3　ベンチマーク

## 3.1　ドメイン

ベンチマークは、明示的な依存構造を持つ合成ドメインからなる。各エンティティは一つの基底前提と、その前提から決定される派生属性を持つ。

```
headquarters
├── nearest_station
│   └── commute_line
├── office_district
│   └── delivery_zone
└── logo_color
```

このうち `headquarters` が基底前提であり、`station`, `line`, `district`, `zone` は依存的に再計算される属性である。`logo_color` は前提更新と無関係な安定属性として置くこともできるが、本稿の中心評価は依存属性に置く。

### 3.2　タスク列

各実験は $E$ 個のエンティティと $T$ 個の逐次タスクから成る。各エンティティはある task で導入され、その後、少なくとも二つ以上の task を隔てて前提更新を受ける。更新時には、基底前提だけでなく、依存属性も新しい前提に基づいて再提示される。

この設計により、モデルは新しい前提を学ぶだけでなく、旧前提に依存していた知識構造を再編しなければならない。

### 3.3　学習例

各例は単純な QA 形式で与える。

```
Question: Company 003 □  headquarters □□□□
Answer: Tokyo
```

更新後には同じ entity に対して Osaka 系の答えが提示される。したがって、旧前提と新前提は、モデルにとって直接に矛盾する学習信号となる。

## 4　評価指標

本稿では完全一致を用いて評価する。ただし、表記揺れによる人工的な不一致を避けるため、地名接尾辞や表記上の差異については正規化を施した。主指標は次の三つである。

**全体正答率**　全体の正答率。

**依存整合性 (DC)**　派生属性に限った正答率。前提更新がどれだけ下流へ伝播したかを測る。

**更新成功率**　更新された事実に限った正答率。新知識の獲得能力を測る。

加えて、T1 時点の知識が T5 時点でどれだけ保持されているかを旧タスク保存の代表値とし、各アダプタの現在知識・保持知識の性能も分けて測る。

## 5　方法

### 5.1　E-lite

E-lite は再提示ベース条件である。過去に学習した事実を信頼度重みつきで保持し、現在タスクに再提示を加える。ただし、明示的に矛盾した旧事実には信頼度減衰を与え、再提示の重みを下げる。E-lite の役割は、矛盾シナリオに適応した再提示ベース継続学習の基準条件を与えることである。

### 5.2 F-v2c

F-v2c は前提認識制御器である。前提と依存属性の関係を DAG として保持し、ある前提が更新されたとき、その下流にあたる依存属性だけを選択的に再提示する。

ここで重要なのは、すべての高信頼事実を再提示するのではなく、依存更新に必要な再提示だけを絞り込んで選ぶことである。これにより、無関係な再提示によるノイズを抑えつつ、前提更新後の依存整合性を回復する。

### 5.3 F-multi

F-multi は多アダプタ分離条件である。単一の LoRA アダプタに現在知識と過去知識を混在させる代わりに、それらを二つのアダプタに分離する。

**現在アダプタ** 現在タスクと依存更新を担当する。

**保持アダプタ** 過去に無効化された旧事実を保持する。

推論時には、現在の実験では理想振り分け（対象例がどちらに属するかを既知として振り分ける方式）を用いる。これは実運用設定ではない。F-multi は実用可能な構成ではなく、保持と更新の衝突を部分空間分離が原理的に緩和しうるかを切り出すための機構的切除実験として設計されている。

## 6 実験結果

### 6.1 T2 collapse の一貫性

もっとも重要な結果は、最初の前提更新以降に T2 collapse がテストした全条件で一貫して現れることである。モデルサイズやアーキテクチャに依存せず、LoRA 更新は旧知識を保持したまま新知識を積み増すのではなく、旧知識の表現を上書きする方向に働く。ここでいう上書きとは、前提更新後に旧知識の保持が急減し、新知識の獲得と旧知識の保持が両立しないパターンを指す。

この結果は、LoRA による逐次更新が上書き的であることを示している。E-lite も F-v2c も、この collapse を根本的には防がない。両者ができるのは、あとから選択的再提示を用いて部分的に回復することだけである。

### 6.2 F-v2c による依存回復

F-v2c は後半タスクの依存整合性を安定して改善する。とくに依存更新を絞り込んで行う設計により、単純な再提示だけでは到達できない水準に一貫して到達する。

この結果は、前提更新を伴う継続学習において、重要なのが単なる保持ではなく、依存構造に沿った選択的修復であることを示している。

### 6.3 F-multi による保持と更新の分離

F-multi は、保持と更新の衝突を完全には解消しないが、単一アダプタでは得られない非ゼロの旧タスク保持を初めて実現する。これは現在タスクの更新方向と過去知識の保持方向を別の部分空間に分離することが、有効な緩和策であることを示す。

ただし、保持アダプタの絶対性能は低い。旧タスクの信号は残るが、高忠実度の知識構造がそのまま保存されるわけではない。この点で、多アダプタ分離は救済ではあるが、完全な解決ではない。

# 7 考察

## 7.1 LoRA は蓄積ではなく上書きする

本稿の結果は、LoRA ベース継続学習が矛盾を含む更新に対して蓄積より上書きに近いことを示している。これは破滅的忘却の一種ではあるが、単なる性能低下ではない。前提更新が派生知識を巻き込むことで、内部整合性そのものが崩れる。

## 7.2 前提認識型再提示の役割

F-v2c の意義は、前提更新を単なる新規タスクとしてではなく、依存再編成を必要とする構造的変化として扱った点にある。保持すべきなのは古い事実の総量ではなく、現在有効な前提に対して整合した下流知識である。

## 7.3 多アダプタ分離の限界

F-multi は非ゼロの旧タスク保持を与えるが、保持忠実度は低い。このことは、パラメータ水準での保存の限界を示唆する。空間分離は方向衝突を緩和するが、それだけで高忠実度の長期知識保持を実現するには足りない。

## 7.4 構造持続の観点からの読み

本稿の結果は、構造持続の最小形式 [1]の観点からも読むことができる。以下は事後的な読み（reading）であり、理論からの事前予測ではない。前提更新を伴う逐次学習では、有効な知識状態の集合が急速に縮小し、その累積損失が増大する。T2 collapse は、その縮小が急激に生じる点として理解できる。F-v2c による依存更新は、この損失の蓄積を抑える介入であり、F-multi による多アダプタ分離は、維持資源を別部分空間に確保しようとする試みとして読める。もっとも、保持忠実度の低さが示すように、パラメータ的な分離だけでは高忠実度の長期保持を十分には回復できない。

# 8 限界

本稿にはいくつかの限界がある。

第一に、ベンチマークは合成的であり、依存関係は明示的かつ決定論的である。現実の知識依存はより多様で、多段で、しばしば曖昧さを含む。決定論的 DAG は依存の追跡を容易にするため、本稿の結果は問題を易しくした条件での結果であり、現実の曖昧な依存構造のもとではさらに悪い結果が出る可能性がある。

第二に、F-multi の振り分けは理想条件（対象例の所属を既知として振り分ける方式）であり、実運用で必要となる学習型の振り分けはまだ扱っていない。したがって

F-multi の結果は性能上界として読むべきであり、実運用ではこれを下回ることが予想される。

第三に、大規模モデルの一部は単一 seed に依存しており、完全な統計的安定性までは示していない。

第四に、保持アダプタの低忠実度が rank 制約、データ不足、共有ベースモデルの干渉のいずれに起因するかは、まだ切り分けられていない。

第五に、本稿の結果は LoRA ベースの更新に限定されており、LoRA rank の変更、QA 以外のフォーマット、full fine-tuning での検証は未実施である。

## 9 結論

本稿では、前提更新を伴う継続学習において、本実験条件では LoRA ベースのパラメータ的更新が上書き的に振る舞うことを示した。前提認識制御器は依存整合性を改善し、多アダプタ分離は非ゼロの旧タスク保持を与える。しかし、保持忠実度はなお低く、パラメータ水準での保存には限界が残る。

したがって、矛盾を含む長期的知識更新において、パラメータ的な適応だけで知識整合性を維持し続けることは難しい。これらの結果は、高忠実度の長期保持には、パラメータ的な更新に加えて、外部的な知識構造の維持・再編成機構が必要であることを示唆する。本稿の役割は、その限界と、そこに対する部分的な救済策を、前提更新という明示的な設定のもとで示すことにある。

## References

[1] Sunagawa, A. 構造持続の最小形式. 2026.

[2] Sunagawa, A. 論理一貫性維持の構造持続的記述. 2026.

[3] Sunagawa, A. 持続知能の混成構成. 2026.