

構造持続と継続学習における破滅的忘却

— 構造推定層における前提更新による構造的忘却の記述と実験 —

Akihito Sunagawa

2026年4月12日

要旨

大規模言語モデルに新しい知識を逐次的に学習させると、古い知識が壊れることがある。しかし、すべての忘却が同じではない。ある前提が変わったとき、その前提に依存していた知識の連鎖がまとめて崩れる場合がある。本稿ではこれを構造的忘却と呼び、単一の事実の喪失と区別する。

7モデル（1.5B～72B、4系統）で LoRA による逐次学習を行い、三つの条件を比較した。第一は過去の事実を再提示する基準条件（E-lite）、第二は前提の依存構造を追跡して選択的に再提示する条件（F-v2c）、第三は現在知識と過去知識を別々のアダプタに分離する条件（F-multi）である。全モデル・全条件で、最初の前提更新以降に旧知識の保持が急減した。LoRA は知識を積み上げるというより、上書きに近く振る舞う。前提依存を追跡して選択的に再提示すると依存整合性は改善するが、旧知識の保持忠実度は低いままである。多アダプタ分離は非ゼロの旧知識保持を与えるが、高忠実度の長期保持にはなお届かない。少なくとも本実験条件では、LoRA によるパラメータ更新だけでは依存知識の整合した再編を十分に担えないことが示される。

1 はじめに

対になる LLM companion は、推論時に未整理の更新や矛盾が残ると論理一貫性が劣化し、外部整理がその悪化を抑える方向を扱った。本稿は、継続学習において前提更新が引き起こす破滅的忘却を扱う。

長期的に運用される大規模言語モデルは、新しい事実を逐次的に学習し続けなければならない。ユーザの住所が変わる、企業の本社が移転する、制度が改定される、科学的知見が更新される。このときモデルは、単に新しい事実を加えるだけでは足りない。ある更新が既存の前提を覆すなら、その前提に依存していた知識の連鎖も同時に更新されなければならない。

この点で、前提更新を伴う継続学習は、通常の知識追加と異なる。たとえば「会社 X の本社は東京である」が「会社 X の本社は大阪である」に更新されたなら、最寄駅、通勤路線、オフィス街、配送区域といった派生知識もそれに合わせて更新されるべきである。古い本社と新しい最寄駅を同時に保持してしまう系は、単に古い知識を忘れたのではなく、内部的に不整合である。

本稿の問いは、LoRA ベースの継続学習が、この種の前提更新をどこまで扱えるか、である。より具体的には、LoRA は知識を積み上げるのか、それとも新しい更新によって古い表現を上書きするのか。また、前提依存を明示的に制御する再提示や、複数アダプタへの空間分離は、この問題をどこまで緩和できるのか。

本稿では、前提-帰結依存を明示した合成ベンチマークを構築し、E-lite、F-v2c、F-multi の三条件を比較する。その結果、本実験条件では LoRA は上書き的に振る舞い、前提認識制御器と多アダプタ分離はそれを部分的に緩和するものの、高忠実度の長期保持にはなお限界が残ることを示す。

2 問題設定

2.1 前提が変わると何が壊れるか

本稿では、ある更新が既存の前提を覆し、その前提に依存する知識の再構成を必要とするにもかかわらず、その連鎖が崩れる忘却を構造的忘却と呼ぶ。ここで問題なのは、古い知識そのものを保存できるかどうかだけではない。現在有効な前提に対して、知識全体が整合しているかが問われる。

より直感的に言えば、構造的忘却は「一つの事実を間違える」ことではなく、「上流の前提が変わったのに、その下流にぶら下がる知識群と一緒に更新されない」ことである。上流だけが新しく、下流が古いまま残ると、モデルは新旧の知識を同時に抱えた不整合な状態になる。

したがって、評価すべきなのは旧タスクの保持だけではない。新しい前提の導入後に、派生知識がどれだけ一貫して更新されるか、すなわち依存整合性が同時に問われる。

2.2 研究課題

本稿では、次の三点を問う。

(1) LoRA ベース継続学習は、前提更新を受けたときに知識を蓄積するのか、それとも上書きするのか。(2) 前提認識型の再提示は、単純な再提示よりも派生知識の整合性を改善するか。(3) 多アダプタ分離は、保持と更新の衝突を緩和できるか。

3 ベンチマーク

3.1 ドメイン

ベンチマークは、明示的な依存構造を持つ合成ドメインからなる。各エンティティは一つの基底前提と、その前提から決定される派生属性を持つ。重要なのは、「一つの更新が複数の下流属性に連鎖する」ように設計してある点である。

たとえば架空の企業について、本社所在地が基底前提であり、そこから最寄り駅、通勤路線、オフィス街、配送区域が連鎖的に決まるとする。以下の表は、本社所在地が東京から大阪に変わったときに、下流の属性がどう連鎖して変わるかを示す。

属性	更新前	更新後
本社所在地	東京	大阪
最寄り駅	東京駅	大阪駅
通勤路線	山手線	大阪環状線
オフィス街	丸の内	梅田
配送区域	東日本	西日本

本社所在地の更新だけを覚えて最寄り駅や通勤路線が古いまま残ると、不整合が発生する。本稿が測りたいのは、まさにこの「連鎖更新の失敗」である。ロゴ色のような本社に依存しない属性は、本稿の中心評価からは外す。なお、実際のベンチマークは英語の QA データセットで実施している。

3.2 タスク列

各実験は E 個のエンティティと T 個の逐次タスクから成る。各エンティティはあるタスクで導入され、その後、少なくとも二つ以上のタスクを隔てて前提更新を受ける。更新時には、基底前提だけでなく、依存属性も新しい前提に基づいて再提示される。

本稿では、逐次タスクを $T1, T2, \dots, T5$ と書く。 $T1$ は最初の学習段階、 $T5$ は五番目の最終学習段階を表す。したがって「 $T5$ 時点の $T1$ 保持」とは、すべての更新を終えた最後の時点で、最初のタスク $T1$ の知識がどれだけ残っているかを測る量である。

この設計により、モデルは新しい前提を学ぶだけでなく、旧前提に依存していた知識構造を再編しなければならない。言い換えれば、「新しい事実を一つ足す」課題ではなく、「古い前提にぶら下がっていた知識全体を組み替える」課題として設計している。

3.3 学習例

各例は単純な QA 形式で与える。

質問: 企業003 の本社所在地はどこか。 回答: 東京

質問: 企業003 の最寄り駅はどこか。 回答: 東京駅

更新後には同じ企業に対して大阪系の回答が提示される。したがって、旧前提と新前提は、モデルにとって直接に矛盾する学習信号となる。

ここで重要なのは、モデルが本社所在地だけを東京から大阪に置き換えればよいわけではない点である。最寄り駅や通勤路線も同じ更新方向に揃わなければ、依存整合性は回復しない。

4 評価指標

本稿では完全一致を用いて評価する。ただし、表記揺れによる人工的な不一致を避けるため、地名接尾辞や表記上の差異については正規化を施した。主指標は次の三つである。

定義 4.1 (全体正答率). 全体の正答率。

定義 4.2 (依存整合性 (DC)). 派生属性に限った正答率。前提更新がどれだけ下流へ伝播したかを測る。

定義 4.3 (更新成功率). 更新された事実に限った正答率。新知識の獲得能力を測る。

加えて、T1 時点の知識が T5 時点でどれだけ保持されているかを旧タスク保存の代表値とし、各アダプタの現在知識・保持知識の性能も分けて測る。

ここで T5 は最終更新後の評価時点を表す。したがって「T5 時点の T1 保持」は、最後の更新を終えたあとでも、最初に学習した知識がどれだけ再生できるかを表す。更新成功率が高くてもこの値が低ければ、新知識は入っているが旧知識は失われていることになる。

5 方法

5.1 E-lite

E-lite は再提示ベース条件である。過去に学習した事実を信頼度重みつきで保持し、現在タスクに再提示を加える。ただし、明示的に矛盾した旧事実には信頼度減衰を与え、再提示の重みを下げる。

E-lite の役割は、矛盾シナリオに適応した再提示ベース継続学習の基準条件を与えることである。

5.2 F-v2c

F-v2c は前提認識制御器である。前提と依存属性の関係を DAG として保持し、ある前提が更新されたとき、その下流にあたる依存属性だけを選択的に再提示する。

ここで重要なのは、すべての高信頼事実を再提示するのではなく、依存更新に必要な再提示だけを絞り込んで選ぶことである。これにより、無関係な再提示によるノイズを抑えつつ、前提更新後の依存整合性を回復する。

5.3 F-multi

F-multi は多アダプタ分離条件である。単一の LoRA アダプタに現在知識と過去知識を混在させる代わりに、それらを二つのアダプタに分離する。

定義 5.1 (現在アダプタ). 現在タスクと依存更新を担当する。

定義 5.2 (保持アダプタ). 過去に無効化された旧事実を保持する。

推論時には、現在の実験では理想振り分け（対象例がどちらに属するかを既知として振り分ける方式）を用いる。これは実運用設定ではない。F-multi は実用可能な構成ではなく、保持と更新の衝突を部分空間分離が原理的に緩和しうるかを切り出すための機構的切除実験として設計されている。

6 実験結果

以下でまず、主要三条件の最終時点の結果をまとめる。ここで T5 は最終タスクを学習し終えた時点、T5 時点の T1 保持はその時点で最初のタスク T1 の知識がどれだけ残っているかを表す。表では見やすさのため、F-v2c-dependency-refresh を F-v2c、F-multi-adapter を F-multi と略記する。

条件	T5 依存整合性	T5 更新成功率	T5 時点の T1 保持
E-lite	0.189 ± 0.096	0.400 ± 0.173	0.167 ± 0.289
F-v2c	0.333 ± 0.000	0.583 ± 0.144	0.000 ± 0.000
F-multi	0.367	0.500-0.750	0.500

この表からまず分かるのは、F-v2c が依存整合性を改善する一方で旧知識保持は回復しないことである。これに対し F-multi は非ゼロの旧知識保持を与えるが、保持アダプタ単体の忠実度はなお低い。以下では、この三条件の差を順に見る。

モデル別に見ると、Qwen 1.5B、Qwen 7B、Llama 70B、Qwen 72B では、E-lite から F-v2c への移行で依存整合性が明確に改善し、F-multi はその改善を維持するか、わずかに上回る。DeepSeek 32B は E-lite の時点で比較的高い整合性を示すが、F-multi でさらに改善する。Gemma 4 31B だけは例外で、F-v2c 単体では依存整合性が低下し、F-multi で部分的に回復する。このため、本稿の主な傾向は「F-v2c が依存整合性を回復し、F-multi が保持を追加する」だが、Gemma 4 31B については更新フォーマットとの相性問題を考慮する必要がある。

6.1 最初の前提更新で旧知識が崩れる

もっとも重要な結果は、最初の前提更新の直後に、旧知識の保持が全条件で一貫して急減することである。モデルサイズやアーキテクチャに依存せず、LoRA 更新は旧知識を保持したまま新知識を積み増すのではなく、旧知識の表現を上書きする方向に働く。ここでいう上書きとは、前提更新後に旧知識の保持が急減し、新知識の獲得と旧知識の保持が両立しないパターンを指す。

この結果は、LoRA による逐次更新が上書き的であることを示している。E-lite も F-v2c も、この急落を根本的には防がない。両者にできるのは、選択的再提示によって部分的に回復することにとどまる。

6.2 F-v2c による依存回復

F-v2c は後半タスクの依存整合性を安定して改善する。とくに依存更新を絞り込んで行う設計により、単純な再提示だけでは到達できない水準に一貫して到達する。

この結果は、前提更新を伴う継続学習において重要なのが、単なる保持ではなく、依存構造に沿った選択的修復であることを示している。

6.3 F-multi による保持と更新の分離

F-multi は、保持と更新の衝突を完全には解消しないが、単一アダプタでは得られない非ゼロの旧タスク保持を実現する。これは現在タスクの更新方向と過去知識の保持方向を別の部分空間に分離することが、有効な緩和策であることを示す。

ただし、保持アダプタの絶対性能は低い。旧タスクの信号は残るが、高忠実度の知識構造がそのまま保存されるわけではない。この点で、多アダプタ分離は救済ではあ

るが、完全な解決ではない。

7 考察

7.1 LoRA は蓄積ではなく上書きする

本稿の結果は、LoRA ベース継続学習が、矛盾を含む更新に対して蓄積より上書きに近いことを示している。これは破滅的忘却の一種ではあるが、単なる性能低下ではない。前提更新が派生知識を巻き込むことで、内部整合性そのものが崩れる。

7.2 前提認識型再提示の役割

F-v2c の意義は、前提更新を単なる新規タスクとしてではなく、依存再編成を必要とする構造的変化として扱った点にある。保持すべきなのは古い事実の総量ではなく、現在有効な前提に対して整合した下流知識である。

7.3 多アダプタ分離の限界

F-multi は非ゼロの旧タスク保持を与えるが、保持忠実度は低い。このことは、パラメータ水準での保存の限界を示唆する。空間分離は方向衝突を緩和するが、それだけで高忠実度の長期知識保持を実現するには足りない。

7.4 構造持続の最小形式から見た解釈

本稿の結果は、構造持続の最小形式の観点から事後的に読むこともできる。前提更新を伴う逐次学習では、有効な知識状態の集合が急速に縮小し、その累積構造消耗量が増大する。最初の前提更新直後の崩れは、その縮小が急激に表面化した点として理解できる。F-v2c による依存更新は、この構造消耗の蓄積を抑える介入として読める。F-multi による多アダプタ分離は、維持資源を別部分空間に確保しようとする試みとして読める。しかし、保持忠実度の低さが示すように、パラメータ的な分離だけでは高忠実度の長期保持を十分には回復できない。

ここでも基準モデルとの比較を明示できる。継続学習における基準モデルを「過去の知識を信頼度に基づいて再提示する」方式 (E-lite) とする。E-lite は再提示の量と信頼度減衰を制御するが、前提と帰結の依存構造には立ち入らない。これに対し F-v2c は、ある前提が更新されたとき、その下流の依存属性だけを選択的に再提示する。すなわち、再提示の対象選択を依存構造に基づいて行う。結果として、依存整合性は E-lite の 0.189 から F-v2c の 0.333 へ改善する (Qwen 1.5B、各条件 seed 3

の平均)。他モデルでは、Llama 70B、Qwen 7B/27B/72B で F-v2c が E-lite を上回り、DeepSeek 32B では同値（ともに 0.333）であった。Gemma 31B では逆転が生じている（E-lite 0.400、F-v2c 0.200）が、この逆転は seed 依存であり（seed 001-002 では $F - v2c \geq E - lite$ ）、F-v2c の descendant_update_weight による勾配の不安定化が特定の初期パラメータで生じたものと考えられる。同じ Gemma 31B において F-multi は正常に機能している（seed 001-002 で 0.533）ことから、アルゴリズムの本質的な限界ではなく、学習設定との相互作用として扱うのが妥当である。この改善の主な要因は、再提示の対象を依存構造に基づいて選択するようにしたことにある。ただし、F-v2c は量（再提示件数の絞り込み）や除外ポリシーも同時に変更しているため、依存構造の寄与を完全に分離するにはさらなるアブレーションが必要である。以上を踏まえると、本結果は、継続学習ドメインにおいても、依存構造を区別する枠組みが信頼度ベースの基準モデルに対して追加の説明力を持ちうることを示唆する。

推論時の構造劣化 companion の §8 では、外部代謝が構造持続に寄与する対象系として、内部に長期的な矛盾解消代謝機構を持たず（条件 (i)）、かつ推論呼び出しの境界を越えて信念を持ち越す機構を持たない（条件 (ii)）系を定めた。LoRA ベース継続学習は、重みの更新という形で条件 (ii) を部分的に緩める仕組みである。推論呼び出しを越えて状態を持ち越す手段が、prompt ではなくパラメータそのものに移る。しかし、本稿の結果が示すのは、条件 (ii) を緩めるだけでは不十分だという点である。パラメータ更新は、新しい信号に反応して表現を変えはするが、既存の派生知識との整合を自律的に取り直す機構、すなわち条件 (i) に相当する矛盾解消代謝を備えていない。F-v2c が依存整合性を改善するのは、この欠けた機構を前提認識型の再提示という外部プロセスで補うからであり、F-multi の限界は、空間分離が資源配分の操作にとどまり、条件 (i) の代替にはならないためである。本稿の結果は、推論時 companion の補助命題と整合的に読める。すなわち、条件 (i)(ii) のいずれか一方だけを緩めても外部代謝の寄与は消えず、長期一貫性の維持には依然として矛盾解消代謝機構が必要である。

この見方に立てば、本稿の結果は LoRA 固有の問題にとどまらない可能性を示唆する。矛盾を含む逐次更新のもとでは、知識の絡まり、表現のドリフト、容量飽和といった異なる機構が、いずれも構造を維持できる有効状態の集合を縮小させる。既存手法はその速度を遅らせることはできても、縮小そのものを止めるとは限らない。高忠実度の長期保持を考えるなら、パラメータ空間の外で更新履歴と依存関係を管理する仕組みが検討対象になる。

7.5 持続知能への含意

本稿と推論時の構造劣化 companion を合わせると、持続知能では少なくとも三つの役割を区別して考える必要があることが見えてくる。第一に、パラメータ的適応である。新しい課題や局所的更新に素早く反応する能力は不可欠だが、それだけでは高忠実度の長期保持と矛盾管理を担えない。第二に、外部代謝である。更新された知識と無効化された知識を時間的・条件的に整理し、検索可能な形に再編成する機構が必要である。第三に、応答生成の忠実化である。知識が取得されても、応答がそれに従うとは限らないためである。

この三者は相互に代替できない。パラメータ的適応だけでは長期保持が弱く、外部記憶だけでは局所的適応と出力反映が不足し、応答生成の改善だけでは保持されていない知識を救えない。したがって、持続知能は単一の工夫としてではなく、これらを組み合わせた混成構成として考えるのが自然である。ただし、その統合方法の詳細は別稿の課題として残る。

8 限界

本稿にはいくつかの限界がある。

第一に、ベンチマークは合成的であり、依存関係は明示的かつ決定論的である。現実の知識依存はより多様で、多段で、しばしば曖昧さを含む。したがって、本稿の結果は問題を易しくした条件での結果であり、現実の曖昧な依存構造のもとではさらに悪い結果が出る可能性がある。

第二に、F-multi の振り分けは理想条件（対象例の所属を既知として振り分ける方式）であり、実運用で必要となる学習型の振り分けはまだ扱っていない。したがって F-multi の結果は性能上界として読むべきであり、実運用ではこれを下回ることが予想される。

第三に、大規模モデルの一部は単一 seed に依存しており、完全な統計的安定性までは示していない。

第四に、保持アダプタの低忠実度が rank 制約、データ不足、共有ベースモデルの干渉のいずれに起因するかは、まだ切り分けられていない。

第五に、本稿の結果は LoRA ベースの更新に限定されており、LoRA rank の変更、QA 以外のフォーマット、full fine-tuning での検証は未実施である。

9 結論

本稿では、前提更新を伴う継続学習において、本実験条件では LoRA ベースのパラメータ的更新が上書き的に振る舞うことを示した。前提認識制御器は依存整合性を改善し、多アダプタ分離は非ゼロの旧タスク保持を与える。しかし、保持忠実度はなお低く、パラメータ水準での保存には限界が残る。

推論時の構造劣化 companion と合わせると、推論時の未整理上書きと継続学習における破滅的忘却は、いずれも構造を維持できる有効状態の集合が制約の蓄積によって縮小する現象として読むことができる。本稿が与えるのは、そのうち継続学習側の問題を、前提更新という明示的な設定のもとで示す一つの具体例である。両 companion を通じて得られる単純な含意は、持続知能に必要なのは単なる更新能力ではなく、更新履歴と依存関係を外部で整理し再利用できる機構だ、という点である。