

有限CSPにおける構造持続の予測力

— Mixed-SAT/NAE-SAT と Exp43c q-coloring による Route A 経験的検証 —

Akihito Sunagawa

2026年4月12日

要旨

本補論は、構造持続理論の Route A に属する有制限約充足問題において、累積構造消耗 L が単なる制約数より強い予測情報を持つかを検証する。

単一の制約族、たとえば 3-SAT だけ、または NAE-SAT だけを見るなら、各制約の drift は定数である。したがって

$$L = m \cdot d$$

となり、 L は raw constraint count m の定数倍にすぎない。この設定では、 L が raw count より良いかを問うことは原理的に縮退している。

そこで本補論では、同じインスタンス内に 3-SAT 制約と 3-NAE-SAT 制約を混ぜる Mixed-CSP を用いる。3-SAT の drift は

$$d_{\text{SAT}} = \log(8/7) \approx 0.1335$$

であり、3-NAE-SAT の drift は

$$d_{\text{NAE}} = \log(4/3) \approx 0.2877$$

である。raw count は両者を同じ 1 制約として数えるが、 L は制約の質を drift-weighted に数える。この差により、構造持続理論の経験的主張を非縮退に検査できる。

2026-04-22 に事前登録済み primary run を実行した。全 12,000 インスタンスが正常に完走し、timeout は 0、malformed encoding は 0 であった。leave-one-mixture-out の予測比較では、primary predictor である $L + n$ モデルが raw count + n baseline を大きく上回った。

model	log loss	Brier	accuracy@0.5
L_plus_n	0.0970	0.0299	0.9631
cnf_count_plus_n	0.1010	0.0304	0.9631
first_moment	0.1489	0.0482	0.9457
raw_density	0.7447	0.2524	0.6279
raw_plus_n	0.7525	0.2539	0.6159
raw_count	0.7708	0.2798	0.5139

事前登録された四つの判定基準はいずれも通過した。

- primary support: L_plus_n log loss 0.0970 < raw_plus_n 0.7525
- strong support: raw_plus_n に対する相対改善 87.1% (閾値 10%)
- theory-pure support: first_moment 0.1489 < raw_plus_n 0.7525
- encoding guardrail: L_plus_n 0.0970 <= cnf_count_plus_n 0.1010

この結果は、 L が単なる制約数ではなく、制約が解空間を削る質的差を予測情報として運ぶことを示す。これは Bernoulli-CSP universality class に対する経験的支持であり、SAT 単独の結果を finite CSP class 内へ拡張する最初の非縮退な prospective test である。

2026-04-23 には、Exp43c q-coloring primary validation も freeze 済み threshold-local protocol のもとで実行された。4,000 インスタンスが正常に完走し、timeout と malformed encoding は 0 であった。leave-one-q-out の予測比較では、theory-specified predictor fm_plus_n が best primary raw baseline を上回った。

model	mean held-out log loss
fm_plus_n	0.440189
first_moment	0.446814
raw_density	0.780910
density_plus_n_q	2.804019
cnf_count_plus_n_q	7.700105
raw_plus_n_q	8.567224

Exp43c の結果は、SAT / NAE-SAT mixed CSP だけでなく、SAT 構文の外側に見える graph-coloring family でも、first-moment / drift coordinate が raw / density / encoding-size baselines より out-of-sample に強いことを示す。ただし、これは absolute q-coloring threshold の予測ではなく、frozen threshold-local window 内での feasibility prediction である。

外部再実行については、Mixed-CSP の requested outside-group rerun set が 3 名の外部実行者により 3/3 clean success として完了した。さらに Exp43c q-

coloring でも、1 名の外部実行者が同じ frozen package を Windows 環境で再実行し、4,000 行、checked core mismatches 0、TIMEOUT 0、MALFORMED 0、および同じ qualitative support decision を返した。したがって Route A では、Mixed-CSP と Exp43c q-coloring という二つの frozen package について、著者環境外での再実行成功が得られている。ただし、これは Route A empirical package の外部再現性を強めるものであり、非CSP branch や理論全体の普遍法則化を単独で閉じるものではない。

1 目的

構造持続理論の最小形式では、状態集合の縮小は対数構造消耗として蓄積される。制約充足問題では、状態集合は候補割当ての集合であり、各制約はその集合を一定割合だけ削る。

ランダム 3-SAT では、一様な割当てが単一節を破る確率は $1/8$ であり、単一節を満たす確率は $7/8$ である。したがって各節による drift は

$$d_{\text{SAT}} = -\log(7/8) = \log(8/7).$$

同様に、3-NAE-SAT では全て真または全て偽の 2 通りが禁止されるため、単一 NAE 制約を満たす確率は $6/8 = 3/4$ であり、

$$d_{\text{NAE}} = -\log(3/4) = \log(4/3).$$

このとき混合インスタンスの累積構造消耗量は

$$\begin{aligned} L &= \\ & m_{\text{SAT}} \log(8/7) \\ & + \\ & m_{\text{NAE}} \log(4/3). \end{aligned}$$

第一モーメント法は、候補割当て数の期待値を

$$\begin{aligned}
E[\#SAT] &= \\
&2^n e^{-L} \\
&= \\
&\exp(n \log 2 - L)
\end{aligned}$$

と与える。したがって

$$F = n \log 2 - L$$

は、充足割当て数の第一モーメント対数である。

本補論の問いは、第一モーメントそのものを証明することではない。それは制約族の仕様から従う。問いは、その L または $n \log 2 - L$ が、raw count や raw density よりも、有限インスタンスの feasibility を out-of-sample に予測するかである。

2 単一 family での縮退

NAE-SAT 単独で

$$L = m \log(4/3)$$

を用いて feasibility を予測しても、これは raw count m と完全に同値である。3-SAT 単独でも同じである。

したがって、単一 family 内で

`$L normalization > raw count$`

を主張することはできない。回帰モデルでは係数が定数倍に変わるだけで、予測性能は同一になる。

非自明な検査には、少なくとも二つの条件が必要である。

第一に、制約ごとの drift が異なること。第二に、評価 endpoint が raw count だけでは区別できない差を含むこと。

Mixed-SAT/NAE-SAT はこの条件を満たす。たとえば $n = 120$ 、density $d = 2.5$ では raw count は全 mixture で $m = 300$ に固定される。しかし SAT/NAE の比率を変えると L は変わる。

mixture	raw count	qualitative drift	observed SAT rate
pure SAT	300	low	1.000
25% NAE	300	low-medium	1.000
50% NAE	300	medium	1.000
75% NAE	300	high	0.145
pure NAE	300	highest	0.000

raw count はこれらを全て同一視する。 L は NAE 制約を SAT 制約より重く数えるため、この差を区別できる。

3 実験設計

3.1 インスタンス

primary grid は以下で構成される。

- $n \in \{80, 120, 160\}$
- density $d = m/n \in \{2.0, 2.5, 3.0, 3.5\}$
- mixture:
 - pure SAT
 - 75% SAT / 25% NAE
 - 50% SAT / 50% NAE
 - 25% SAT / 75% NAE
 - pure NAE
- 各 cell 200 インスタンス

合計は

$$3 \times 4 \times 5 \times 200 = 12000$$

である。

exact-one-3-SAT は、drift が大きく CNF encoding size との交絡も強いため、初回 primary には含めない。これは保守的な判断である。SAT/NAE の二型混合だけでも $L \neq \text{constant} \times m$ は成立し、raw count との非縮退比較が可能である。

3.2 endpoint

primary endpoint は feasibility である。すなわち、インスタンスが SAT か UN-SAT かを予測する。

これは重要である。以前の計算コスト補論では、条件つき発見確率 $P(\text{found} \mid \text{SAT})$ と solver cost を扱った。しかし Route A の第一モーメント構造が直接支配するのは、まず解空間の体積と feasibility であって、特定ソルバーの探索コストではない。

したがって本補論では、solver conflict count ではなく SAT rate を primary に置く。solver cost は別の問いであり、存在論的 L と発見論的 c を混同しない。

3.3 予測モデル

事前登録では、leave-one-mixture-out cross-validation により、以下のモデルを比較した。

- raw_count: raw semantic constraint count
- raw_density: m/n
- raw_plus_n: raw count + n
- L_only: drift-weighted L
- L_plus_n: $L + n$
- first_moment: $n \log 2 - L$
- cnf_count_plus_n: CNF clause count + n

primary comparison は $L_plus_n < raw_plus_n$ である。first_moment $< raw_plus_n$ は theory-pure support とした。cnf_count_plus_n は encoding guardrail であり、 L の勝利が単に CNF 展開サイズの勝利でないかを検査する。

4 実行整合性

4.1 aborted attempt と verifier fix

最初の primary attempt は 563 行で停止した。2 行が malformed_encoding と判定されたためである。これは CNF encoding の論理バグではなく、verifier 側の false positive であった。

原因は、PySAT / MiniSat が unconstrained variable を返却 model から省略することがある一方で、初期 verifier が全変数 $1, \dots, n$ の assignment を要求していたこ

とである。SAT/NAE 制約の意味論評価に必要なのは、実際に制約に現れる変数だけである。

修正後 verifier は、semantic constraints に現れる変数集合だけを要求する。修正後、以下の検査を通した。

- archived malformed rows 2 件の regression replay
- default agreement test 1000 instances
- stress agreement test $n = 80, d = 2.0$, 500 instances
- stress agreement test $n = 160, d = 2.0$, 500 instances

いずれも agreement failure は 0 であった。aborted attempt は OSF bundle と git history に forensic archive として残し、official primary analysis からは除外している。

4.2 official primary

修正後、official primary を別ファイルでゼロから実行した。

```
official primary rows: 12000/12000
status: $succeeded = 12000$
timeouts: 0
malformed encodings: 0
SAT feasible rows: 6753
UNSAT rows: 5247
```

このため、primary analysis は aborted attempt に依存しない。

5 結果

5.1 primary model comparison

leave-one-mixture-out の結果は以下である。

model	log loss	Brier	accuracy@0.5
L_plus_n	0.0970	0.0299	0.9631
cnf_count_plus_n	0.1010	0.0304	0.9631
first_moment	0.1489	0.0482	0.9457

model	log loss	Brier	accuracy@0.5
L_only	0.4731	0.1601	0.7626
raw_density	0.7447	0.2524	0.6279
raw_plus_n	0.7525	0.2539	0.6159
raw_count	0.7708	0.2798	0.5139

primary predictor L_plus_n は raw_plus_n を大きく上回った。

$$0.0970 < 0.7525.$$

相対改善は

$$1 - \frac{0.0970}{0.7525} \approx 0.871$$

であり、事前登録の strong support 閾値 10% を大幅に超える。

5.2 first moment

理論的に最も純粋な predictor は

$$n \log 2 - L$$

である。これは係数を固定した第一モーメント対数であり、追加の自由係数を持たない。

この first_moment も raw_plus_n を明確に上回った。

$$0.1489 < 0.7525.$$

ただし L_plus_n には負ける。これは有限サイズ補正を示唆する。first_moment は n と L の係数を $(\log 2, -1)$ に固定するが、L_plus_n は有限 n の偏りを logistic regression の係数で吸収できる。

したがって、first_moment と L_plus_n の差

$$0.1489 - 0.0970 = 0.0519$$

は、第一モーメント理論からの finite-size deviation を測る経験的余白として読める。

5.3 encoding guardrail

L_{plus_n} は cnf_count_plus_n にもわずかに勝った。

$$0.0970 \leq 0.1010.$$

この margin は小さい。しかし SAT/NAE の二型混合では、それは予想される。CNF encoding では SAT 制約は 1 clause、NAE 制約は 2 clauses で表せる。一方、drift ratio は

$$\frac{\log(4/3)}{\log(8/7)} \approx 2.15$$

であり、CNF clause count の比 2.00 と近い。したがって SAT/NAE-only grid では、 L と CNF clause count はほぼ比例する。

この条件で L_{plus_n} が cnf_count_plus_n に勝つことは、方向としては理論と整合するが、margin が狭くなるのは構造的に自然である。

将来、exact-one 制約を stress extension として含めると、この guardrail はより強く分離される。exact-one-3-SAT の drift は

$$\log(8/3) \approx 0.981$$

であり、SAT に対して約 7.3 倍である。一方、pairwise CNF encoding の clause count は SAT に対して 4 倍である。ここでは L と CNF size の比例性がより大きく破れる。

ただし、exact-one は feasibility の飽和と encoding size 交絡が強いため、初回 primary から外した。この判断は、最初の empirical Route A test を清潔に保つための保守的設計である。

6 理論的位置づけ

6.1 SAT 単独から Bernoulli-CSP class へ

ランダム 3-SAT は、構造持続理論にとって最も硬い Route A anchor の一つである。状態集合は $\{0, 1\}^n$ 、測度は counting measure、各制約の縮小率は仕様から直接計算できる。

しかし 3-SAT 単独では、 $L = m \log(8/7)$ であり、raw count と縮退する。したがって、3-SAT で L が有効であることは重要だが、「制約の質を drift-weighted に数えることが raw count より強い」という主張はまだ検査されていない。

Mixed-SAT/NAE-SAT はこの間隙を埋める。raw count を固定したまま、constraint type の drift を変えることで、 L の非自明な予測力を検査する。

今回の Mixed-CSP 結果は、Bernoulli-CSP universality class に対して、Lean での formal layer に対応する empirical counterpart を与える。具体的には `Survival.BernoulliCSPUniversality`、`Survival.NAESATChernoffCollapse`、および関連する exposure / Chernoff wrapper 群に対応する経験的検査である。すなわち、固定割当てに対する Bernoulli bad-event exposure として表現できる異なる CSP 制約族が、同じ L -based coordinate で feasibility を整理される。

Exp43c q-coloring は、この方向を graph-coloring family へ広げる。Lean 側の q-coloring formalization は fixed-coloring edge exposure を扱う。一方、Exp43c の empirical endpoint は full graph q-colorability である。したがって Exp43c は q-coloring threshold theorem ではない。より正確には、fixed-coloring exposure から得られる first-moment / drift coordinate

$$n \log q - L$$

が、threshold-local な q-colorability feasibility を raw edge count、density、CNF encoding-size baseline よりよく予測した、という経験的検査である。

6.2 何を主張し、何を主張しないか

本補論が主張するのは次である。

1. SAT/NAE mixed finite CSP では、 $L + n$ が raw count + n より feasibility を強く予測した。
2. $n \log 2 - L$ という theory-pure predictor も raw baseline を上回った。
3. CNF encoding size baseline との比較でも、 $L + n$ は少なくとも同等以上であった。
4. Exp43c q-coloring では、 $n \log q - L$ に対応する `fm_plus_n` が raw / density / CNF-size baselines を leave-one-q-out で上回った。
5. したがって、 L または first-moment coordinate は単なる制約数ではなく、制約の質的 drift を含む予測座標として機能する。

本補論が主張しないのは次である。

1. すべての CSP で同じ定数係数が成立する、とは主張しない。
2. drift から solver cost の感度指数 c を一点予測できる、とは主張しない。
3. XOR-SAT のように多項式構造が支配する family を primary empirical cost test に使える、とは主張しない。
4. Bootstrap percolation や branching process がこの意味で Route A anchor である、とは主張しない。
5. 独立再現なしに universal law が確立した、とは主張しない。

ここで得られたのは、Bernoulli-CSP class 内での empirical universality support である。より強い universal law of tendency には、formal theorem 4 の昇格と独立再現が必要である。

6.3 LLM 実験との対応

LLM 側の Exp.40/41/42 は、scope-as-repair が quality-blind baseline より予測力を持つことを示した。Mixed-CSP は、それとは全く異なる hard combinatorial domain で、drift-weighted L が raw baseline より予測力を持つことを示す。

両者の機構は同じではない。LLM の attribution-as-repair と SAT/NAE の bad-event exposure は別の現象である。

共通しているのは、単純な「量」ではなく、構造の質を区別する座標が out-of-sample の予測力を持つ点である。LLM では scope / attribution の質が効き、Mixed-CSP では constraint drift の質が効く。

この意味で、Mixed-CSP は「例を一つ足した」のではなく、方法論を横断した検査である。すなわち、quality-blind / raw-count baseline に対して、structure-aware coordinate が prospective に勝つかを問う同じ型の検査である。

7 限界

第一に、Mixed-CSP 結果は SAT/NAE の二型混合に限定される。Exp43c は q-coloring への拡張を与えたが、これは単独で universal law を確立するものではない。Cardinality-SAT への拡張は自然な次段階だが、本補論の validated claim ではない。

第二に、encoding guardrail の margin は小さい。これは SAT/NAE では CNF clause ratio と drift ratio が近いためである。この点は exact-one stress extension でより強く検査できる。

第三に、対象は feasibility であり、solver cost ではない。solver cost については、既存の計算コスト補論が存在と発見を分けて扱っている。本補論の結果を、任意ソルバーの runtime 予測へ直接外挿してはならない。

第四に、有限サイズ効果が残る。first_moment が raw baseline を大きく上回る一方で L_plus_n に負けることは、理論的第一モーメントだけでは finite n の補正を完全には吸収できないことを示す。

第五に、公式 primary の前に verifier false positive による aborted attempt が存在する。ただしこれは archive され、原因は unconstrained variable の model omission と特定され、修正後の regression / agreement test を通過した。official primary は修正後に別ファイルでゼロから実行され、aborted attempt は分析から除外されている。

8 再現性

関連ファイルは以下にある。

file	role
analysis/route_a_mixed_csp/ mixed_csp_preregistration.md	事前登録
analysis/route_a_mixed_csp/ run_mixed_csp.py	実行 runner
analysis/route_a_mixed_csp/ analyze_mixed_csp.py	primary analysis
analysis/route_a_mixed_csp/ debug_mixed_csp_encoding.py	verifier regression / agreement diagnostics
analysis/route_a_mixed_csp/ mixed_csp_primary_official_2026-04-22.jsonl	official primary raw records
analysis/route_a_mixed_csp/ mixed_csp_results.json	machine-readable results
analysis/route_a_mixed_csp/ mixed_csp_results_summary.md	human-readable results

Exp43c q-coloring の関連ファイルは以下にある。

file	role
analysis/exp43_qcoloring/ exp43c_threshold_local_preregistration_draft.md	fresh threshold-local preregistration
analysis/exp43_qcoloring/ exp43c_calibration_closeout.md	calibration closeout
analysis/exp43_qcoloring/ exp43c_freeze_package.md	frozen primary package
analysis/exp43_qcoloring/ exp43c_primary_report.md	primary validation report
analysis/exp43_qcoloring/ config/ exp43c_primary_config.json	primary grid
analysis/exp43_qcoloring/src/ evaluate_primary.py	frozen evaluation script
analysis/exp43_qcoloring/ exp43c_true_outside_rerun_01_philia_channel.md	first returned true outside-group rerun

G7 outside-group replication layer:

package	returned outside runs	status
Mixed-CSP	3	3/3 clean success
Exp43c q-coloring	1	1/1 returned clean success

この G7 layer は、各 package の frozen 手順が著者環境外でも実行可能であり、qualitative support decision が回復されることを示す。Mixed-CSP は requested set として完了している。一方、Exp43c は現時点で first returned success であり、追加の outside return があれば別途記録する。

OSF addendum:

- zip: <https://osf.io/download/69e826573b65e7b53bfd8b7e/>
- manifest: <https://osf.io/download/69e8265a30357781bafd90d6/>

公式 primary の commit は

1dadb73dd435347977c47be066002460f136ea00

であり、結果導線の commit は

a5fc8e2

である。

9 結論

Mixed-CSP primary は、構造持続理論の Route A empirical test として、事前登録された四つの判定基準を全て通過した。

3-SAT と 3-NAE-SAT は raw count では同じ 1 制約として見えるが、解空間を削る drift は異なる。 L はこの差を加法的に累積し、finite CSP の feasibility を out-of-sample に予測した。

これは、構造持続理論における L が単なる量ではなく、制約の質を含む座標として機能することの経験的証拠である。SAT 単独の Route A anchor は、Mixed-SAT/NAE-SAT により Bernoulli-CSP class へ一段拡張された。

さらに Exp43c q-coloring により、SAT 構文の外側に見える graph-coloring family でも、first-moment / drift coordinate が raw / density / encoding-size baseline を上回ることが示された。これは Route A width を一段広げる primary evidence である。

外部再実行の層では、Mixed-CSP が 3 名の外部実行者で 3/3 clean success を返し、Exp43c q-coloring も 1 名の外部実行者で clean success を返した。したがって、Route A では二つの frozen package について著者環境外での再実行成功が得られている。

ただし、本補論は universal law の最終宣言ではない。正確な位置づけは、SAT、LLM contradiction repair、Mixed-CSP feasibility、Exp43c q-coloring feasibility で、structure-aware coordinate が quality-blind / raw baseline を上回った、という Level 2 universality candidate への強い支持である。

残る課題は、formal theorem 4 による tendency law への昇格、Cardinality-SAT などへのさらなる幅拡張、追加の独立再現、そして非CSP / observational branch への外部検証である。